

UNIVERSIDAD DE SANTIAGO DE CHILE
FACULTAD DE INGENIERÍA
Departamento de Informática



**Sistema escalable para la detección de necesidades en escenarios de
catástrofe natural**

Esteban Andrés Abarca Rubio

Profesor guía: Nicolás Hidalgo Castillo

Profesor co-guía: Erika Rosas Olivos

Trabajo de titulación presentado
en conformidad a los requisitos
para obtener el título de Ingeniero
Civil en Informática

2016

© **Esteban Andrés Abarca Rubio**, 2016



• Algunos derechos reservados. Esta obra está bajo una Licencia Creative Commons Atribución-Chile 3.0. Sus condiciones de uso pueden ser revisadas en:
<http://creativecommons.org/licenses/by/3.0/cl/>.

RESUMEN

Twitter es una red social que cuenta con millones de usuarios en todo el mundo y, en Chile, alcanza cerca de los 1.700.000 accesos diariamente. Sus usos van desde ser un *microblog* personal hasta la entrega de información o comunicación entre pares. Es por ello que, en épocas de necesidad, como lo es el periodo inmediato luego de la ocurrencia de una catástrofe natural, las personas tienden a publicar sus experiencias dentro de éste servicio.

Teniendo en cuenta lo anterior es que se construyó un sistema, basado en el paradigma de procesamiento de *streams*, capaz de recoger información de manera automática desde *Twitter* — los denominados *tweets* — y procesarlos a fin de detectar si es que un *tweet* corresponde a uno en el que el usuario haga mención alguno de los tipos de necesidad que el sistema es capaz de detectar. El sistema hace uso de la información implícita (contenido del *tweet* o metadatos), para presentar la necesidad como un punto en un mapa geográfico del país, de modo que la información obtenida pueda ser tomada por las autoridades correspondientes para que, de esta forma, facilite el proceso de toma de decisiones en cuanto al envío de ayuda a una determinada área dadas las necesidades expresadas por la población.

Para lograrlo se utilizaron las metodologías programación extrema y KDD para construir una aplicación que utilizase un clasificador de textos para realizar la detección de necesidades, mediante los cuales se logra ubicar y clasificar correctamente datos obtenidos del terremoto de Concepción ocurrido el 27 de febrero del año 2010. Además, se prueba la efectividad del operador detector de ubicación para suplir la carencia de datos de geolocalización en los metadatos de *Twitter*.

Este trabajo se enmarca en el proyecto FONDEF IDeA (Dos etapas), código ID15I10560 en el que participa un equipo de investigación de la universidad.

Palabras Claves: Programación extrema; KDD; Clasificador; *Twitter*; Detección de necesidades; Geolocalización; *Stream processing*; Clasificador de texto; Redes sociales; Herramienta de apoyo a desastres

ABSTRACT

Twitter is a social network that already has millions of users worldwide and, in Chile, reaches about of 1.7 millions of accesses daily. Its uses range from being a personal microblog up to information delivery and communication between peers. It's because of this that in emergencies, such as the immediate period after a natural catastrophe, people tends to post their experiences on this service.

With this in mind, we have built a system based on the stream processing paradigm, that it's able to get automatically information from *Twitter* — *tweets* — and process it to detect if a user's *tweet*'s content it's about an user need. The system use the implicit information in the *tweet* (metadata) to render the need as a geographical position in a map, thus authority can use the given information and ease the desition making process of sending help to affected areas with the information given by the population.

The methodology used were extreme programming and KKD in order to build a text's classifier to detect people's needs. With these two methods was possible to classify and place correctly the data obtained from Concepción's earthquake at February the 27, 2010. We have evaluated the effectiveness of the proposed location recognizer created to supply the lack of geolocalization data in Twitter's metadata.

This project was developed in the context of the FONDEF IDeA (Two stages), code: ID15I10560, where a University's research team is working on.

Keywords: Extreme programming; KDD; Classifier; Twitter; Detect people's Need; Geolocalization; Stream processing; Text's classification; Social networks; Post-disaster support tool

Dedicado a...

AGRADECIMIENTOS

Agradezco a

TABLA DE CONTENIDO

1	Introducción	1
1.1	Antecedentes y motivación	1
1.2	Descripción del problema	2
1.3	Solución propuesta	2
1.4	Objetivos y alcance del proyecto	3
1.4.1	Objetivo general	3
1.4.2	Objetivos específicos	3
1.4.3	Alcances	3
1.5	Metodologías y herramientas utilizadas	4
1.5.1	Metodología	4
1.5.2	Herramientas de desarrollo	8
1.6	Organización del documento	9
2	Marco teórico y estado del arte	11
2.1	Marco teórico	11
2.1.1	Sistemas de procesamiento de <i>streams</i>	11
2.1.2	Minería de texto	12
2.1.3	Bases de datos no relacionales	15
2.2	Estado del arte	17
2.2.1	Plataformas de procesamiento para desastres	17
2.2.2	Procesamiento de datos a gran escala	18
2.2.3	Clasificación de eventos	21
3	Requerimientos	24
3.1	Proceso de toma de requerimientos	24
3.2	Historias de usuario y criterios de aceptación	26
4	Diseño e implementación	30
4.1	Arquitectura del sistema	30
4.1.1	<i>Back-end</i>	31
4.1.2	<i>Front-end</i>	31
4.2	Características del sistema	32
4.3	Decisiones de diseño	33
4.3.1	Comunicación	33
4.3.2	Persistencia	35
4.3.3	Sistema de procesamiento	36
4.3.4	Fuente de datos	37
4.3.5	Términos de búsqueda	38
4.3.6	Categorización de necesidades	39
4.3.7	Clasificador	40
4.3.8	Interfaz web	41
4.4	Implementación del sistema	43
4.4.1	<i>Front-end</i>	43
4.4.2	<i>Back-end</i>	52
5	Evaluación del sistema	65
5.1	Cumplimiento de requerimientos	65
5.2	Evaluación del clasificador	66
5.3	Topología y replicación	67
5.4	Funcionamiento en alto tráfico	74

6 Conclusiones	78
Glosario	81
Referencias bibliográficas	87
Apéndice A Recolección de <i>tweets</i> con RapidMiner	88
Apéndice B Claves para el uso de la <i>stream</i> API de <i>Twitter</i>	90

ÍNDICE DE TABLAS

Tabla 3.1	Resumen de las HU ligadas al procesamiento	26
Tabla 3.2	Resumen de las HU ligadas a la interfaz	27
Tabla 3.3	Criterios de aceptación para HU de procesamiento	27
Tabla 3.4	Criterios de aceptación para HU de interfaz.	28
Tabla 4.1	<i>Streaming endpoints</i> de <i>Twitter</i>	37
Tabla 4.2	Reemplazo de entidades en texto.	57
Tabla 4.3	Ejemplo de <i>stemming</i> para la palabra 'presentar'.	60
Tabla 5.1	Estados dentro del conjunto de entrenamiento cuya categoría es alimento.	67
Tabla 5.2	Estadísticas de los operadores diversos eventos.	70
Tabla 5.3	Prueba sistema completo utilizando 1000 eventos.	71
Tabla 5.4	Prueba sistema completo utilizando 2000 eventos.	71
Tabla 5.5	Prueba sistema completo utilizando 4000 eventos.	71
Tabla 5.6	Prueba sistema completo utilizando 8000 eventos.	72
Tabla 5.7	Prueba sistema utilizando 30000 eventos.	72
Tabla 5.8	Resultado esperado del operador de ubicación.	72
Tabla 5.9	Nueva prueba al sistema con 30000 eventos.	73
Tabla 5.10	Nivel general de replicación de la topología.	73
Tabla 5.11	Nivel máximo de replicación de la topología.	74

ÍNDICE DE ILUSTRACIONES

Figura 1.1	Diagrama de flujo de Programación Extrema.	6
Figura 1.2	Proceso para el manejo y tratamiento de datos según la metodología KDD.	8
Figura 2.1	Arquitectura típica de sistemas de procesamiento de <i>streams</i>	12
Figura 2.2	Clasificación supervisada en general.	13
Figura 2.3	Representación del funcionamiento de Apache Storm.	20
Figura 3.1	Captura del estado final del tablero Kanban.	29
Figura 4.1	Arquitectura del sistema.	30
Figura 4.2	Esquema que representa la comunicación entre aplicaciones del sistema detector de necesidades.	34
Figura 4.3	Ejemplo de documento en la colección Markers.	36
Figura 4.4	Ejemplo de documento en la colección queries.	38
Figura 4.5	Formato archivo de entrada.	40
Figura 4.6	Fichero clasificador en <i>c : /DeNe/</i>	41
Figura 4.7	Ejemplo de marcador en el mapa con su categorización y <i>tweet</i> que lo generó.	42
Figura 4.8	Ejemplos de agrupamiento basados en distancia y categorías.	43
Figura 4.9	Selector de fechas JDateRangeSlider.	44
Figura 4.10	Implementación de evento de detección de cambios en la línea temporal.	46
Figura 4.11	Selector de fechas presente en la aplicación.	46
Figura 4.12	Categorías para marcadores.	47
Figura 4.13	Iconos de cluster para categoría agua.	47
Figura 4.14	Iconos de cluster para categoría alimento.	47
Figura 4.15	Iconos de cluster para categoría electricidad.	48
Figura 4.16	Iconos de cluster para categoría comunicación.	48
Figura 4.17	Iconos de cluster para categoría personas.	48
Figura 4.18	Iconos de cluster para categoría seguridad.	48
Figura 4.19	Ejemplo de documento en la colección Markers.	49
Figura 4.20	Ejemplo de documento en la colección Status.	50
Figura 4.21	Implementación del <i>Spout</i> del sistema.	53
Figura 4.22	Implementación del método <i>execute</i> del <i>bolt</i> de idioma.	54
Figura 4.23	Implementación del método <i>execute</i> del <i>bolt</i> del filtro de consultas.	56
Figura 4.24	Topología general del sistema.	64
Figura 5.1	Métricas del clasificador.	66
Figura 5.2	Implementación topología de detección de necesidades.	68
Figura 5.3	Esquema de la topología en el caso de máxima actividad.	69
Figura 5.4	Distribución de eventos presente en el conjunto de datos utilizado para evaluar.	74
Figura 5.5	Recopilación de datos desde el <i>stream</i>	75
Figura 5.6	Uso de CPU durante la simulación.	76
Figura 5.7	Archivos abiertos durante la simulación.	77
Figura A.1	Proceso de iteración en RapidMiner.	88
Figura A.2	Subproceso de recolección de estados en RapidMiner.	88
Figura A.3	Estadísticas de <i>tweets</i> con geolocalización.	88
Figura B.1	Obtención de claves paso uno.	90
Figura B.2	Obtención de claves paso dos.	90
Figura B.3	Obtención de claves paso tres.	91

Figura B.4	Obtención de claves paso final.	91
------------	---	----

ÍNDICE DE ALGORITMOS

Algoritmo 4.1	Algoritmos de utilización de filtros	45
Algoritmo 4.2	Algoritmos de generación de primera y tercera estadística.	50
Algoritmo 4.3	Algoritmos de generación de segunda estadísticas.	51
Algoritmo 4.4	Algoritmos de términos recurrentes.	56
Algoritmo 4.5	Algoritmos de ubicación geoográfica.	58
Algoritmo 4.6	Algoritmos de eliminación de <i>stopwords</i>	59

CAPÍTULO 1. INTRODUCCIÓN

1.1 ANTECEDENTES Y MOTIVACIÓN

Los desastres naturales en Chile han sido frecuentes en los últimos años. Sólo por mencionar algunos de los más recientes: la erupción del volcán Chaitén (Mayo, 2008), el terremoto en Tocopilla (Noviembre, 2007), el terremoto en Concepción (2010), el incendio de las Torres del Paine (Diciembre, 2011), el incendio en Valparaíso (Abril, 2014), la erupción del volcán Villarrica (Marzo, 2015), los aluviones en el norte (Marzo, 2015), entre otros. Dependiendo de las características de la emergencia, surgen en la población diversos tipos de necesidades: alimentos, agua, luz eléctrica, refugio, rescate o comunicación, entre otras. Muchas veces éstas pueden no ser detectadas por las autoridades; al menos, no de forma expedita, lo que resulta perjudicial para las personas que intentan sobrellevar la crisis de la mejor manera posible, cuando se ve involucrada una necesidad básica, como la falta de agua, donde la vida de los afectados puede verse comprometida. El problema anteriormente descrito, no es sólo para las autoridades; Imran et al. (2014a), señalan que el comportamiento humano ante crisis como éstas, no es quedarse esperando por ayuda o huir en pánico, sino de intentar tomar decisiones rápidas en base a la información que conocen. Esto quiere decir que existe gente dispuesta a ayudar, aun siendo ellos mismos los afectados; pero no siempre disponen de la información necesaria para saber hacia dónde apuntar sus esfuerzos. Será útil, dado todo lo anterior, tener algún medio que concentre las necesidades que pueda tener una población dentro del país, para acudir en su auxilio dada la ocurrencia de una emergencia catastrófica, como las mencionadas anteriormente.

Los académicos del proyecto FONDEF IDeA (Dos etapas), código ID15110560 de la Universidad de Santiago de Chile, están trabajando en el desarrollo de una plataforma de procesamiento de flujo de datos generados en contextos de desastres; se busca proveer la infraestructura necesaria para la generación de herramientas capaces de apoyar la toma de decisiones en escenarios de desastres. Esta plataforma hace uso de la información generada por los usuarios en redes sociales como fuente de datos. Para realizar la prueba de concepto de la plataforma se planea desarrollar tres aplicaciones base, orientadas a facilitar la coordinación de voluntarios, detección de necesidades y difusión de información de interés.

En este trabajo, en particular, se ataca el problema de la detección de necesidades de la población y servir de apoyo para la construcción de la plataforma de *streaming*, en relación a qué operadores se han de construir y cómo ha de estructurarse el sistema para operar sobre datos a nivel nacional.

1.2 DESCRIPCIÓN DEL PROBLEMA

El problema que aborda esta memoria, es el hacer uso de la información generada por la población por medio de *Twitter* para que, en caso de alguna emergencia de carácter nacional, pueda prestarse apoyo en tiempo real a las autoridades encargadas de la toma de decisiones; por ejemplo, dándoles a conocer en qué lugar exactamente se requiere asistir a la población con un determinado tipo de ayuda, según la necesidad que se presente. ¿Cómo detectar y localizar en tiempo real las necesidades expresadas por la población en redes sociales basadas en texto de manera de generar una nueva fuente de datos para mejorar la toma de decisiones?

1.3 SOLUCIÓN PROPUESTA

Se propone un sistema capaz de recolectar y analizar de manera automática los eventos generados en la red social *Twitter* en tiempo real, de manera que, al ocurrir un escenario de desastre, determine si la publicación expresa una necesidad y, en caso de que así sea, determine su posición geográfica.

La solución propuesta consta de dos partes: por una lado la plataforma y lógica de procesamiento capaz de realizar la labor antes mencionada y, por otro, la visualización de estos datos.

La plataforma de procesamiento consiste en un sistema de procesamiento de *streams*, construido utilizando el sistema de computación distribuida de *Apache Storm*, el cual basa su funcionamiento en transformar el problema en un grafo donde cada vértice representa un nodo que realiza una tarea, pudiendo existir múltiples instancias de cada nodo alojadas en un sistema distribuido, como un *cluster* de computadores.. Así, internamente, la plataforma está compuesta de operadores que discriminan cuándo evento debe ser entregado a la aplicación de visualización para ser mostradas al usuario. Uno de estos operadores permitirá realizar la categorización del texto de entrada por medio un un clasificador bayesiano.

1.4 OBJETIVOS Y ALCANCE DEL PROYECTO

1.4.1 Objetivo general

Construir un sistema escalable para la detección de necesidades de la población en tiempo real, para escenarios de desastre natural haciendo uso de *Twitter*.

1.4.2 Objetivos específicos

1. Implementar un método encargado de la recolección de tweets generados dentro del territorio nacional haciendo uso de la API pública de Twitter.
2. Especificar la taxonomía de las necesidades detectadas.
3. Diseñar e implementar el clasificador de necesidades.
4. Definir los elementos de procesamiento para la construcción del sistema capaz de trabajar los datos obtenidos a gran escala.
5. Implementar una arquitectura escalable que soporte la aplicación.
6. Evaluar la aplicación bajo condiciones de alto tráfico, como es el caso de una emergencia nacional.

1.4.3 Alcances

Se utilizan las publicaciones de *Twitter* para llevar a cabo el procesamiento de la información y no se considera, en el marco de este trabajo, el uso de una red social alternativa, no porque no sea posible, sino que con la finalidad de acotar el problema.

Las necesidades que la aplicación detecta no son una lista exhaustiva de las posibles existentes, sino de un subconjunto que se ha considerado más importante en el equipo de trabajo del proyecto. De esta forma se logra acotar el problema reduciendo la cantidad de categorías y permitir una mayor precisión en la clasificación, entendiendo la precisión como la relación de elementos clasificados correctamente sobre el total.

Se considera, para la construcción del clasificador, un subconjunto de un *dataset* compuesto de cuatro millones de *tweets* recogidos durante y posteriormente al terremoto en

Concepción el 27 de Febrero del 2010. Este conjunto de datos ha de ser limpiado previamente pues contiene *tweets* en idiomas diferentes al idioma objetivo de este trabajo.

El sistema sólo trabaja en la detección con *tweets* que estén en español.

La validación se realiza a partir de *datasets* con *tweets* reales, sin embargo los flujos generados son sintéticos y no obtenidos de manera online desde *Twitter*.

1.5 METODOLOGÍAS Y HERRAMIENTAS UTILIZADAS

1.5.1 Metodología

Para la realización de este trabajo se utilizan dos metodologías, la primera está enfocada a la búsqueda de información en bases de datos para realizar la construcción del clasificador de texto, mientras que la segunda, una metodología de desarrollo de aplicaciones ágil, está enfocada en la construcción en sí de las aplicaciones, tanto de la plataforma de procesamiento como de la aplicación de visualización. Ambas son definidas a continuación.

Programación Extrema

La Programación Extrema (*Extreme Programming*, XP desde ahora en adelante), comenzó como un proyecto el 6 de Marzo de 1996. Es uno de los procesos ágiles más populares y ha sido probado exitosamente en compañías e industrias de todos los tamaños, Wells (2013). Su éxito se debe a que hace especial hincapié en la satisfacción del cliente por sobre la entrega de todo lo el software posible.

Esta metodología aporta cinco formas esenciales para mejorar el proceso de desarrollo de software: comunicación, simplicidad, retroalimentación, respeto y coraje. Se busca en establecer una estrecha comunicación entre el equipo de desarrollo y el cliente apuntando paralelamente a evitar el sobre-diseño, pero no limita la creatividad en el sentido de que el equipo de desarrollo pueda arriesgarse para proponer alguna implementación diferente a la planteada por el cliente Siempre se puede obtener retroalimentación de modo que los cambios, en caso de ser necesarios, puedan realizarse lo antes posible.

La metodología originalmente implementa reglas de trabajo, éstas están divididas en cinco áreas. Para la realización de este proyecto no se consideraron estrictamente todas las que señala la metodología, sino se adaptó el proceso al trabajo, justamente como la metodología señala. Las actividades desarrolladas se presentan a continuación.

1. Planeación:

- Se escriben Historias de usuario.
- Se divide el proyecto en iteraciones.
- Al comienzo de cada iteración se planea cómo será.

2. Manejo:

- Se le da al equipo una área de trabajo.

3. Diseño:

- Simplicidad. El mejor diseño es el más simple.
- Se crean *spikes* para reducir el riesgo.
- No se agregan funcionalidades antes de tiempo.
- Hacer uso de técnicas de *refactoring*, cada vez que sea posible.

4. Implementación:

- El cliente siempre está disponible.

5. Prueba:

- Todo el código debe tener pruebas unitarias.
- Cuando se encuentra un *bug*, se crean pruebas.
- Los *test* de aceptación se ejecutan a menudo y sus resultados son publicados.

Estas reglas se fundamentan en los valores que la metodología quiere entregar, éstos ya fueron mencionados, a continuación pasan a ser detallados:

- **Simplicidad:** Se hace lo que se solicitó, pero no más. Ésto maximiza el valor entregado dado una fecha límite. Nuestras metas se alcanzan por medio de pequeños pasos para mitigar errores tan pronto ocurran. Se crea algo de lo que se esté orgullosos y lo se mantiene en el tiempo a costos razonables.
- **Comunicación:** Todos son partes de un equipo y se comunicamos cara a cara a diario. Se trabaja juntos en todo: desde la toma de requerimientos hasta la implementación. Se crea la mejor solución posible al problema.
- **Retroalimentación:** Cada iteración es completada seriamente entregando *software* funcional. Mostraremos nuestro *software* a menudo y prontamente para luego escuchar y aplicar los cambios solicitados. Se habla del proyecto y se adapta el propio proceso a el, no al revés.

- Respeto: Todos dan y reciben el respeto que merecen como miembros del equipo. Todos contribuyen con valor así sea simple entusiasmo. Los desarrolladores respetan la experiencia del cliente y viceversa.
- Coraje: Se dice la verdad sobre el progreso y nuestras estimaciones. No se documentan excusas por si se falla, pues se planea tener éxito. Se adapta a los cambio cuando ocurran.

El proceso de XP puede ser apreciado en la Figura 1.1.




Figura 1.1: Diagrama de flujo de Programación Extrema.
Fuente: Wells (2013)

Knowledge Discovery in Databases (KDD)

Metodología de trabajo para la búsqueda de información en bases de datos, es definida por Fayyad & Uthurusamy (1995) como "el proceso no trivial de identificar patrones válidos, nuevos, potencialmente útiles y en última instancia comprensible en los datos". Surge de la necesidad de manejar grandes volúmenes de datos e involucra simultáneamente varias disciplinas de investigación tales como el aprendizaje automático, la estadística, inteligencia artificial, sistemas de gestión de bases de datos, sistemas de apoyo a la toma de decisiones, entre otras.

Si bien puede variar el usuario, quien es aquel que determina el dominio de la aplicación, es decir, cómo se utilizan los datos, el proceso generalmente considera las siguientes etapas:

1. Selección de datos: consiste en buscar el objetivo y las herramientas del proceso de minería, identificando los datos que han de ser extraídos, buscando atributos apropiados de entrada y la información de salida para representar la tarea. Esto quiere decir que, primero se debe tener en cuenta lo que se sabe, lo que se quiere obtener y cuáles son los datos que nos

facilitarán esa información para poder llegar a la meta, antes de comenzar el proceso como tal.

2. Limpieza de datos: en este paso se limpian los atributos sucios, incluyendo datos incompletos, el ruido y datos inconsistentes. Éstos, en algunos casos, deben ser eliminados, pues pueden contribuir a un análisis inexacto y resultados incorrectos.
3. Integración de datos: combina datos de múltiples procedencias incluyendo múltiples bases de datos, que pueden tener diferentes contenidos y formatos.
4. Transformación de datos: consiste en modificaciones sintácticas llevadas a cabo sobre los datos sin que suponga un cambio en la técnica de minería aplicada. Tiene dos caras, por un lado existen ventajas en el sentido de mejorar la interpretación de las reglas descubiertas y reduce el tiempo de ejecución, por el otro puede llevar a la pérdida de información.
5. Reducción de datos: reducción del tamaño de los datos, encontrando características más significativas dependiendo del objetivo del proceso.
6. Minería de datos: consiste en la búsqueda de patrones de interés que puedan expresarse como un modelo o dependencia de los datos. Se ha de de especificar un criterio de preferencia para seleccionar un modelo de un conjunto de posibles modelos. Además se ha de especificar la estrategia de búsqueda (algoritmo), a utilizar.
7. Evaluación de los patrones: se identifican patrones interesantes que representan conocimiento utilizando diferentes técnicas incluyendo análisis estadísticos y lenguajes de consulta.
8. Interpretación de resultados: Consiste en entender resultados de análisis y sus implicaciones y puede llevar a regresar a algunos pasos anteriores.

La representación del proceso descrito por la metodología KDD es presentada en la Figura 1.2.




Figura 1.2: Proceso para el manejo y tratamiento de datos según la metodología KDD.
Fuente: Iribarra (2015)

1.5.2 Herramientas de desarrollo

A continuación se presentan las herramientas, tanto de *software* como de *hardware* utilizadas para la construcción del sistema de detección de necesidades.

Se ha utilizado diversas herramientas de software para la construcción de la aplicación, éstas son descritas a continuación haciendo especial énfasis en aquellas de gran importancia dentro del desarrollo del proyecto

- Apache Storm: sistema de procesamiento distribuido que basa su procesamiento en dividir el procesamiento en nodos de un grafo dirigido. Permite el procesamiento de eventos en tiempo real.
- MongoDB: sistema de gestión de bases de datos no-SQL capaz de lidiar con altas tasas de tráfico y respuestas rápidas para aplicaciones en tiempo real.
- Mallet: biblioteca de Java que contiene herramientas para el procesamiento de lenguaje natural, clasificación de documentos, extracción de información y otras herramientas de aprendizaje automático sobre texto.
- Play Framework: *framework* para la construcción tanto de aplicaciones Java como Scala, utiliza el modelo de arquitectura de diseño modelo-vista-controlador. Está orientado a la construcción de aplicaciones REST y hace hincapié en la productividad de los desarrolladores.

Además de las herramientas descritas, se hace uso de las una lista de herramientas comunes para el desarrollo de proyectos de *software* presentada a continuación:

- NetBeans (8.1), como herramienta de apoyo a la construcción de la aplicación.
- Sublime Text 3 (Build 3103), como editor de textos.
- MiKTeX (XeLaTeX), para la escritura de la memoria.
- PowerDesigner 16, para la elaboración de diagramas.
- Bitbucket (Git), como repositorio de todo lo referente al proyecto (detector de necesidades, visualizador y documento de memoria).
- Trello (Online), como tablero Kanban para mantener el estado de avance del proyecto.
- YourKit 1.8.0_92 64 bits, para evaluación de *performance* de la aplicación.
- Windows 10 Home Edition (x64), sistema operativo.
- Linux Mint 17.3 (x86), sistema operativo.
- Oracle VirtualBox (5.0.14), utilizado para ejecutar la máquina virtual de Linux sobre Windows.

Herramientas de hardware

Se hace uso del equipo del autor de este trabajo cuyas características técnicas son descritas a continuación:

- Procesador Intel Core i5 2.2 Ghz.
- 8 GB de memoria RAM.
- 1 TB de disco duro.

1.6 ORGANIZACIÓN DEL DOCUMENTO

El resto del documento se organiza de la siguiente manera:

El Capítulo 2, presenta el marco teórico que sustenta la solución implementada y un análisis del estado del arte en términos de las herramientas y técnicas que han sido utilizadas para dar solución a problemas similares.

El Capítulo 3 describe el proceso de toma de requerimientos de la aplicación. Para ello, siguiendo la metodología XP, se usan de historias de usuario y sus correspondientes criterios de aceptación.

El Capítulo 4, se presenta la arquitectura del sistema y las decisiones que llevaron a que se seleccionase ésta, además, describir la implementación de las aplicaciones visualizador y detector de necesidades, incluyendo los elementos que las componen y, en el caso de esta última aplicación, el porqué del uso de una topología en particular.

El Capítulo 5, describe la completitud de las historias de usuario, evalúa el nivel de replicación de los operadores del sistema y su rendimiento en una simulación de una situación real como fue el terremoto de Concepción en febrero del año 2010.

Finalmente en el Capítulo 6, presenta las conclusiones del trabajo realizado, el cumplimiento de objetivos tanto general como específicos, los resultados de los experimentos y trabajo futuro.

CAPÍTULO 2. MARCO TEÓRICO Y ESTADO DEL ARTE

Este capítulo busca realizar una contextualización de los conceptos necesarios para entender el problema que se está tratando por medio de una breve reseña de cada uno. Además, se de a conocer la revisión de los trabajos existentes capaces de realizar tareas similares o basadas en principios similares a los planteados por la solución expuesta de este trabajo.

2.1 MARCO TEÓRICO

Se presentan las definiciones de herramientas y técnicas presentados y que sustentan a la solución implementada.

2.1.1 Sistemas de procesamiento de *streams*

El sistema tradicional de procesamiento, el trabajo por lotes (*batch*), está pensado en que primero los datos son recopilados y almacenados, para luego pasar a ser procesados. Sin embargo, este enfoque introduce una alta latencia en la obtención del resultado deseado, lo que no es útil en casos en que es necesario obtener resultados en tiempo real.

Para realizar este tipo de procesamiento en tiempo real existe otro enfoque, el procesamiento de *streams*, el cual está diseñado para trabajar con datos que llegan al sistema directamente desde la fuente y en gran cantidad y son procesados uno por uno.

Un sistema de procesamiento de *streams* se caracteriza, principalmente, por lo siguiente:

- Opera en memoria: procesamiento continuo en flujos de datos en series de tiempo.
- Escalable: arquitectura optimizada para latencia cercana a cero en grandes volúmenes de datos.
- Escalabilidad a través de la distribución eficiente en múltiples procesadores o servidores.

Su funcionamiento es caracterizado por datos llegando de manera continua a los cuales se les aplica una o más operaciones las cuales pueden filtrar, agregar information, o transformar los datos entrantes.

Conceptualmente su arquitectura es un grafo de operaciones que se comunican entre ellas intercambiando flujos de datos. La Figura 2.1 presenta cómo es una típica arquitectura de estos sistemas, SQLStream (2015).




Figura 2.1: Arquitectura típica de sistemas de procesamiento de *streams*.
Fuente: SQLStream (2015)

Estos sistemas se enfrentan a algunas dificultades como por ejemplo, la cantidad de información que reciben, la cantidad que son capaces hacer fluir por ellos o *throughput* y el tiempo que demoran en ello (latencia).

Existen variados motores de procesamiento de *streams*, sólo por mencionar algunos de ellos: S4 Neumeyer et al. (2010), *StreamCloud* Gulisano et al. (2012), ESC Satzger et al. (2011), *TimeStream* Qian et al. (2013), T-Storm Xu et al. (2014), MillWheel Akidau et al. (2013), Storm Apache (2016b).

2.1.2 Minería de texto

La minería de textos o *text mining* es una rama de la lingüística computacional que trata de obtener información y conocimiento a partir de conjuntos de datos que en principio no tienen un orden o no están dispuestos en origen para transmitir esa información, Fernández (2011). Para explicar este concepto, primero se introduce el concepto de minería de datos o *data mining*.

Minería de datos

Para la minería de datos los datos son la materia prima, ésta se convierte en información que posteriormente es tratada y utilizada para convertirla en conocimiento. Reune áreas como la estadística, inteligencia artificial, bases de datos, y procesamiento masivo. Molina (2002) la define como “la integración de un conjunto de áreas que tienen como propósito la identificación de un conocimiento obtenido a partir de las bases de datos que aporten un sesgo

hacia la toma de decisión”.

La principal diferencia de la minería de datos con respecto a la minería de textos es que la primera utiliza bases de datos como materia prima, mientras la segunda hace uso de documentos para ello.

Una de las aplicaciones de la minería de textos es la clasificación de documentos. Esta práctica consiste en el uso de técnicas de aprendizaje automático para asignar categorías a un determinado texto, para ello existen algoritmos de clasificación con los cuales pueden construirse clasificadores capaces de agrupar eventos en categorías pre-establecidas.

Clasificadores

En el campo del procesamiento de lenguaje natural el detectar patrones es una parte central. La clasificación es la tarea de seleccionar la etiqueta correcta para una entrada dada. Cada entrada es considerada como aislada de las demás, y el conjunto de etiquetas (o categorías), es definido con anterioridad.

Un clasificador es llamado “supervisado” si ha sido construido a partir de un conjunto de datos de entrenamiento o *corpus* de entrenamiento. La Figura 2.2 muestra el proceso de entrenamiento y uso de un clasificador. (a) Durante el entrenamiento, un extractor de características es utilizado para convertir cada entrada a un conjunto de características, estos capturan la información básica de cada conjunto de entrada que es usada para clasificar. Pares de estos conjuntos y etiquetas son la entrada para el algoritmo que contruye el modelo de clasificación. (b) Durante la predicción se realiza el mismo procedimiento, pero sin entregar como entrada la etiqueta correspondiente, se pasa al modelo generado para obtener su predicción sobre la pertenencia a una etiqueta.

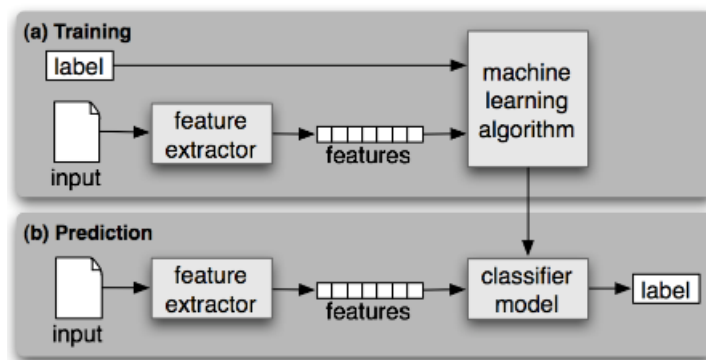


Figura 2.2: Clasificación supervisada en general.
Fuente: Steven Bird & Loper (2009)

El modelo de clasificación coonstruido debe evaluarse para decidir si es preciso. Para ello se requiere un conjunto de datos de evaluación que generalmente corresponden a un

subconjunto entrada. El conjunto de entrenamiento se separa en dos categorías: los datos de entrenamiento y los datos de evaluación. Comúnmente, se utiliza un 10% del conjunto total para formar los datos de evaluación, Steven Bird & Loper (2009).

La métrica más simple para evaluar un clasificador es la precisión (*accuracy*), la cual corresponde al ratio de entradas clasificadas correctamente. Matemáticamente:

$$Accuracy = \frac{TP}{TP + FP}$$

TP y FP corresponden respectivamente a valores correctamente clasificados (*true positives*) y valores clasificados incorrectamente (*false positives*), también conocidos como "Errores tipo I". Adicionalmente, existe otras dos métricas: TN y FN que, respectivamente corresponden a valores correctamente no clasificados como elementos de una etiqueta específica (*true negatives*) y los conocidos como "Errores tipo II", valores que no pertenecen a una etiqueta y han sido clasificados como tales (*false negatives*). Con estos valores se pueden obtener dos nuevas métricas: El *recall* y el medida F (*F-Score*).

El *recall*, indica el ratio de elementos clasificados correctamente y matemáticamente se define como sigue:

$$Recall = \frac{TP}{TP + FN}$$

Por otro lado, la medida F combina precisión y *recall* para entregar un puntaje, dado por la siguiente función:

$$F_{\beta} = (1 + \beta^2) \frac{Accuracy \cdot Recall}{(\beta^2 \cdot Accuracy) + Recall}$$

Típicamente se utiliza la medida armónica donde β toma el valor 1, quedando la función como sigue:

$$F1 = 2 \frac{Accuracy \cdot Recall}{Accuracy + Recall}$$

Se dice que es la medida armónica, pues pondera de igual manera ambos ratios, Raschkowski (2016).

Existen diferentes tipos de métodos de aprendizaje de máquina utilizados para construir clasificadores, dentro de ellos existen: *Naïve Bayes*, máxima entropía y árboles de decisión.

Los árboles de decisión corresponden a un diagrama de flujo con el que se decide la etiqueta para una entrada. Los diagramas de flujo consisten en nodos de decisión, los que comprueban los conjuntos de características y las hojas que asignan las etiquetas. El más simple

de ellos es llamado un *decision stump*, el cual consiste en sólo un nodo de decisión y múltiples hojas, para construirlo se construye para todas las posibles etiquetas y se calcula la precisión para quedarse con aquellos que alcancen la más alta. Entonces, para construir un árbol de decisión con mayor nivel de generalización se van construyendo múltiples *decision stumps* y usando aquellos con más alta probabilidad.

Para el caso de los clasificadores *Naïve Bayes*, Russell (2003), cada elemento del vector de características aporta en la determinación de qué etiqueta ha de ser utilizada. Para cada etiqueta se calcula su probabilidad *a priori*, utilizando como referencia su frecuencia en el conjunto de entrenamiento. Esta probabilidad en conjunto con el aporte de cada elemento del vector determina una probabilidad de pertenencia, se le asigna a la entrada la etiqueta que tenga mayor probabilidad de pertenencia.

Los clasificadores máxima entropía, son similares a los clasificadores bayesianos, pero en lugar de utilizar las probabilidades establecer los parámetros del modelo, utilizan técnicas de búsqueda para encontrar parámetros que maximicen el desempeño del clasificador mediante técnicas de optimización iterativa, las que inician los parámetros en valores aleatorios y los refina mientras se va acercando al óptimo. Su principal desventaja es que toman mucho tiempo en realizar el aprendizaje por el periodo de iteración antes mencionado, Steven Bird & Loper (2009).

Existen herramientas que contienen implementaciones de estos algoritmos, entre otros, y permiten generar clasificadores de manera más fácil y rápida. Se puede mencionar como ejemplo Hall et al. (2009), acrónimo del inglés *Waikato Environment for Knowledge Analysis*, RapidMiner Mierswa (2016) y Mallet McCallum (2002), acrónimo del inglés *MAchine Learning for LanguagE Toolkit*.

En este trabajo se ha utilizado Mallet, herramienta desarrollada por McCallum (2002), en la Universidad de Massachusetts Amherst, La herramienta se encuentra en lenguaje Java y realiza procesamiento de lenguaje natural, clasificación de documentos, *clustering*, extracción de información y otras aplicaciones de aprendizaje de máquina sobre texto. Mallet cuenta con implementaciones de una variedad de algoritmos entre los cuales se encuentran: *Naïve Bayes*, máxima entropía y árboles de decisión. Además, incluye herramientas para evaluar el desempeño de clasificadores mediante el uso de métricas más utilizadas.

2.1.3 Bases de datos no relacionales

Las bases de datos no relacionales se separan de los principios expresados por Codd (1970), pues no utilizan el lenguaje SQL, prácticamente universal en las bases de datos convencionales. Estas últimas organizan la información en tablas, cada una de ellas tiene un

número de columnas o campos especificados por el administrador y filas correspondiente a los datos. Además, estas tablas pueden relacionarse entre sí con relaciones uno a uno entre los elementos o uno a varios, de manera que mediante consultas que combinan varias tablas pueden obtener información de varias de ellas, estas consultas se realizan mediante un sencillo lenguaje estandarizado.

Las bases de datos tradicionales están diseñadas para mantener la integridad de las relaciones, por ejemplo: una tabla "alumnos" esta relacionada con la tabla "calificaciones" y no pueden haber calificaciones para un alumno inexistente.

El problema del modelo antes mencionado está en que son costosas en términos de rendimiento, dadas las garantías ofrecidas sobre los datos y transacciones. Lo que no es problema en lugares donde la información es limitada y se realizan pocas escrituras, pues éstas son caras computacionalmente. El verdadero problema está cuando la cantidad de información es muy grande, donde el uso de bases de datos relacionales obliga a dedicar mucho esfuerzo a la optimización para obtener un resultado aceptable.

Aproximándose a lo no relacional se renuncia a las tablas perfectamente definidas, que garantizan la integridad y donde todo parece predecible, pero se obtiene rapidez y flexibilidad. En el sistema de gestión de base de datos no relacionales como Apache (2015), Sanfilippo (2015), MongoDB (2016), toda la información está en el mismo sitio. Al acceder a los datos de un alumno, siguiendo la línea del ejemplo anterior, toda estará ahí, incluidas sus calificaciones y no existe información relacional, Purriños (2014).

El caso de MongoDB, corresponde es una base de datos no relacional (NoSQL), de código abierto escrita en C++ y orientada al trabajo en documentos. Lo anterior quiere decir que en lugar de guardar los datos en tablas, lo hace en documentos, los que son almacenados como una representación binaria de JSON conocida como BSON.

Una de las diferencias fundamentales con respecto a las bases de datos relacionales es que no es necesario que se siga un esquema; en una misma colección — concepto similar a una tabla en las bases de datos relacionales — se pueden tener distintos esquemas.

MongoDB fue creado para brindar escalabilidad, rendimiento y disponibilidad. Puede ser utilizado en un servidor único como en múltiples. Esto se logra dado que MongoDB brinda un elevado rendimiento, tanto para lectura como para escritura, potenciando la computación en memoria, MongoDB (2016).

En pruebas realizando operaciones habituales dentro de las bases de datos, Macool (2013), demostró que el tiempo de ejecución de MongoDB, como base de datos NoSQL, aventaja significativamente a las bases de datos relacionales más populares como lo son MySQL y PostgreSQL.

2.2 ESTADO DEL ARTE

El problema a abordar consta de tres tópicos centrales: plataformas orientadas a desastres, plataformas de procesamiento escalable y herramientas para la clasificación de eventos. La presente sección aborda los trabajos relacionados con la aplicación que se desea construir en las tres temáticas anteriormente mencionadas.

2.2.1 Plataformas de procesamiento para desastres

El *Qatar Computing Research Institute* ¹, es líder a nivel mundial en la creación de herramientas para dar soporte a desastres naturales usando tecnologías de la información, colaborando con grandes organizaciones como Naciones Unidas, Cruz Roja Internacional y UNICEF. Recientemente, han elaborado distintas aplicaciones (*MicroMappers*, *AIDR*, *UAViators*, etc.), para ayudar a darle sentido al gran flujo de información que reciben los centros de ayuda humanitaria (*Big crisis data*), generada por redes sociales, SMS, imágenes satelitales y aéreas tomadas por drones, que de otra forma serían incapaces de analizar. Tomando la información, estas aplicaciones unen la ayuda de voluntarios y profesionales digitales, quienes están dispuestos a colaborar a través de Internet realizando tareas como identificación o clasificación. Con ésta y el poder del aprendizaje de máquina, se entrenan algoritmos para analizar millones de datos.

Micromappers Patrick Meier & Leson (2014) es una aplicación creada por *Qatar Computing Research Institute*, que permite a voluntarios digitales etiquetar diferente tipos de información para la ayuda en el proceso de respuesta a desastres y desplegarlos en un mapa. En el caso del terremoto de Nepal por ejemplo, los voluntarios han contribuido revisando miles de *tweets* e imágenes para entregar una evaluación de impacto que ayuda a la toma de decisiones. La evolución de esta herramienta está orientada a integrarse con *AIDR* para que la información obtenida de las personas a través de *crowdsourcing* pueda servir para la automatización de proceso de clasificación mediante aprendizaje de máquina, y así subir al análisis de miles a millones de datos generados situaciones de emergencia. Esta plataforma, a diferencia de lo propuesto en el presente trabajo, es una plataforma genérica de procesamiento de datos de crisis o desastres que no aborda el proceso de detección de necesidades, sino más bien, organizar la información que se genera en las diferentes fuentes de datos utilizada.

AIDR (Artificial Intelligence for Disaster Response), Imran et al. (2014b), delega al aprendizaje de máquina la identificación de contenido durante desastres en *Twitter*. Va más allá

¹<http://qcri.com>

de un simple filtro por palabras clave que limitan la búsqueda a ellas y al lenguaje. *textitAIDR* está compuesto de tres partes: el colector, el entrenador y el etiquetador. El primero recolecta y almacena los datos, el entrenador construye un etiquetador automático y permite a usuarios realizar esto dado un conjunto de *tweets* capturados por el colector, el etiquetador analiza los *tweets* clasificados por humanos para automáticamente etiquetar nuevos *tweets*. Esta plataforma no considera un sistema de procesamiento de *streams*, de manera general, plantea una plataforma orientada a cómo generar sistemas automáticos de clasificación de eventos.

UAViators Patrick Meier & Lucas (2016), iniciativa también creada por *Qatar Computing Research Institute*, reúne información generada por drones que entregan imágenes para crear conocimiento sobre el área del desastre en tiempo real. Su procesamiento puede entregar información como una estimación de la población afectada, daños en infraestructura de edificios, líneas de electricidad, carreteras, campamentos base, entre otros. Esta plataforma posee un objetivo muy diferente al planteado por la solución propuesta en esta memoria, sin embargo ambas soluciones pueden ser complementarias.

2.2.2 Procesamiento de datos a gran escala

En los últimos años, un nuevo paradigma de procesamiento se sumó al ya conocido esquema *map-reduce*. Este nuevo paradigma, a diferencia del anteriormente mencionado, es capaz de procesar información online sin requerir de el almacenamiento previo de los datos. Este esquema se adapta de mejor manera la tendencia de extraer conocimiento de las interacciones online de los usuarios. A continuación se presentan algunos de las implementaciones de estos paradigmas de procesamiento.

MapReduce

El *framework* de Google *MapReduce*, Dean & Ghemawat (2008), es un modelo de programación diseñado para procesar conjuntos de datos a gran escala en una modalidad orientada al lote (*batch*) o procesamiento *online*. Este sistema está orientado a programación funcional y utiliza funciones del tipo *map* y *reduce*. *MapReduce* ha logrado gran popularidad en aplicaciones orientadas a grandes volúmenes de datos dado su modelo de programación basado en clave/valor y su escalabilidad. Las soluciones presentadas en Verma et al. (2013), están orientadas al procesamiento de flujos de datos en línea basadas en *MapReduce*. Los autores en Condie et al. (2010), proponen modificaciones a *Hadoop*, que es una implementación de *MapReduce* de código abierto, y que permite que los datos sean canalizados entre los operadores haciéndolo más adecuado a aplicaciones con requerimientos de tiempo real.

Apache S4

S4, Neumeyer et al. (2010), o *Simple Scalable Streaming System*, es un sistema de propósito general, distribuido y escalable que permite que aplicaciones puedan procesar flujos de datos de forma continua y sin restricciones. S4 está inspirado en *MapReduce*, y fue diseñado en el contexto de minería de datos y algoritmos de aprendizaje de máquina en *Yahoo! Labs* para sistemas de publicidad *online*. Cada evento en S4 es descrito como un par (clave, atributo). La unidad básica son los elementos de procesamiento (PEs) y los mensajes que son intercambiados entre ellos. Los PEs pueden emitir o pueden publicar resultados y son alojados en servidores llamados nodos de procesamiento (PNs). Los PNs son responsables de escuchar eventos, rutear eventos a los PEs del nodo y despachar eventos a través de la capa de comunicación. Los eventos son encaminados usando una función de *hashing* sobre los valores de los atributos hacia el PE apropiado. Por otro lado, la capa de comunicación utiliza Zookeeper, Hunt et al. (2010), el cual provee manejo de clusters y reemplazo automático de nodos que fallan. S4 usa encaminamiento estático, es parcialmente tolerante a fallas, y no posee mecanismos de balanceo dinámico de carga.

Actualmente S4 está en fase de incubación en la fundación Apache, pero no ha tenido avances en el proyecto desde el junio del año 2013, cuando se lanzó su versión 0.6.0.

Apache Spark

Spark, Apache (2016a), es una plataforma de computación de código abierto para análisis y procesos avanzados, que tiene muchas ventajas sobre *Hadoop*. Desde el principio, *Spark* fue diseñado para soportar en memoria algoritmos iterativos que se pudiesen desarrollar sin escribir un conjunto de resultados cada vez que se procesaba un dato. Esta habilidad para mantener todo en memoria es una técnica de computación de alto rendimiento aplicado al análisis avanzado, la cual permite que *Spark* tenga unas velocidades de procesamiento que puedan ser hasta 100 veces más rápidas que las conseguidas utilizando *MapReduce*, Tirados (2014).

Apache Storm

Apache Storm es una plataforma similar a S4, está implementado como una API para la computación *streams* de datos en tiempo real desde una o múltiples fuentes de manera distribuida, tolerante a fallos y de alta disponibilidad. *Storm* está principalmente pensado para trabajar con datos que deben ser analizados en tiempo real, Ramos (2015).

Es escalable y garantiza que toda la información será procesada. Presenta *Benchmarks* que señalan que por nodo es capaz de procesar más de un millón de tuplas por segundo.

Un sistema construido haciendo uso de *storm* está compuesto por elementos procesadores de dos tipos: el primero es denominada *spout* y es el encargada de recoger el flujo de datos de entrada. El segundo es denominada *bolt* y es el encargada de la transformación o procesado de los datos, para una transformación compleja se requiere mayor número de *bolts*.

Oficialmente, una aplicación *storm* es representada como puede verse en la Figura 2.3, allí los *spouts* son representados simulando ser llaves de agua desde donde fluyen los datos al sistema y los *bolts* como rayos donde se procesa el flujo.




Figura 2.3: Representación del funcionamiento de Apache Storm.
Fuente: Apache (2016b)

Uno de los puntos fuertes que tiene este sistema, y que está en línea con lo señalado para sistemas de procesamiento de *stream*, es que al crear una topología donde se instancian *bolts* y *spouts*, *Storm* se encarga de escalar el sistema distribuyendo los elementos en sus componentes. Una topología de *Storm* corresponde, en su nivel más alto de abstracción, a un grafo acíclico dirigido, Ramos (2015).

Storm tiene diferentes modos de funcionamiento, referido a la forma en la que se van a compartir los datos entre los componentes. Como modelo de datos, *Storm* utiliza tuplas que son listas de valores con un nombre específico, Ramos (2015), éstas pueden ser enviadas al siguiente nodo de las siguientes formas:

- *Shuffle grouping*: *storm* decide de forma *round robin* la tarea a la que se va a enviar la tupla, de manera que la distribución sea equivalente entre todos los nodos.
- *Fields grouping*: se agrupan los *streams* por un determinado campo de manera que se distribuyen los valores que cumplen una determinada condición a la misma tarea.
- *All grouping*: el *stream* pasa por todas las tareas haciendo multicast.

- *Global grouping*: el *stream* se envía al *bolt* con ID más bajo.
- *None grouping*: es un *Shuffle grouping* donde el orden no es importante.
- *Direct grouping*: la tarea es la encargada de decidir hacia donde emitir especificando el ID del destinatario.
- *Local grouping*: se utiliza el mismo *bolt* si tiene una o más tareas en el mismo proceso.

Storm puede funcionar de dos modos: local y *cluster*. El primero es útil para el desarrollo, pues ejecuta toda la topología en una única JVM, por lo que pueden realizarse fácilmente pruebas de integración, depurar código, etcétera. Este modo simula, haciendo uso de *threads*, cada nodo del *cluster*, Ramos (2015).

El modo *cluster* es considerado el "modo de producción" y es el modo donde el código es distribuido en máquinas diferentes dentro del *cluster*.

La arquitectura de *Storm* se divide en tres componentes:

- *Master Node*: ejecuta el demonio llamado *Nimbus*, el cual es responsable de distribuir el código a través del *cluster*. Realiza la asignación y monitorización de tareas en las distintas máquinas del cluster.
- *Worker Node*: ejecutan el demonio *Supervisor*, el cual se encarga de recoger y procesar los trabajos asignados en la máquina donde está siendo ejecutado. En caso de fallo de uno *Worker Node*, *Nimbus* observa esto y redirige el trabajo a otro.
- *Zookeeper*: si bien no es un componente propio de *Storm*, es necesario para su funcionamiento, pues se encarga de coordinar *Nimbus* y *Supervisor*, además de mantener sus estados, pues ambos son *stateless*, Hunt et al. (2010).

2.2.3 Clasificación de eventos

Por otra parte, la clasificación de texto en servicios de *microblogging*, como *Twitter* es un problema cuya solución tiene diferentes puntos de vista, los métodos tradicionales incluyen hacer uso de una bolsa de palabras para clasificar según el contenido del texto, construcción de n-gramas para clasificar según términos co-ocurrentes o ubicar el texto en una categoría haciendo uso de técnicas de aprendizaje de máquina o *Machine Learning*, Nguyen & Jung (2015). Este último método ya ha sido comprobado por diversos autores, entre ellos Maldonado (2012), quien utilizó este método para realizar su memoria donde clasificaba *tweets* según sentimientos encontrados en el texto, estos podían ser positivos, negativos o neutros, para ello hizo uso de un clasificador *Naïve Bayes* y *Support Vector Machine* (SVM).

En el marco de las jornadas chilenas de la computación Gonzales & Wladdimiro (2014), propusieron un modelo, desarrollado para el proyecto PMI USA 1204: Despliegue ágil de aplicaciones para desastres Hidalgo & Rosas (2014), donde analizaron el rendimiento de una aplicación de clasificación de necesidades básica al ser implementada en un sistema de procesamiento de *streams* como S4. En el se propone un modelo basado en *Yahoo! S4* donde, haciendo uso del paradigma de procesamiento de *streams* de datos, se forma un grafo cuyos nodos (Elementos de procesamiento o PE, por sus siglas en inglés), dividen el procesamiento en pequeñas tareas fácilmente replicables para paralelizar el *pipeline*. En esa ocasión desarrollaron distintos tipos de operadores mencionados a continuación:

- Recolector: haciendo uso de la API de *Twitter* obtiene el *stream* de datos del mismo.
- *Scheduler*: discrimina cada *tweet* según la categoría que pertenece (información, agua, electricidad o alimento), mediante el uso de una bolsa de palabras y la distancia *Hamming*.
- Filtrado: utilizaron en su trabajo un clasificador basado en *machine learning* para verificar la subjetividad de un *tweet*, por lo que ya está demostrado que esta herramienta es capaz de categorizar texto, por lo que puede ser aplicada para las entradas de *Twitter*.
- Relevancia: identificar si una información es o no confiable haciendo uso de la cantidad de publicaciones del usuario, sus seguidores y a quienes sigue para estimar una reputación del autor.
- Ranking: hace uso de la información anterior, decidiendo a qué le entrega mayor importancia.

Los autores concluyeron basándose en la carga computacional la importancia de una replicación adecuada para distribuir la carga entre los operadores, pero no fueron concluyentes en cuánto o qué nivel de replicación es el adecuado o cuándo replicar.

A modo de comentario se señala que diversos autores, entre los que podemos mencionar a Valer (2011), Weng & Lee (2011), Maldonado (2012), han señalado las dificultades que se presentan al trabajar utilizando como entradas los estados públicos (*tweet*) de los usuarios de *Twitter*, dentro de las dificultades señaladas se encuentran, por ejemplo, el acceso a la información; si bien existen accesos públicos a la información estos son restringidos tanto en cantidad como en tiempo: Este punto de acceso permite acceder a un 1% de la información generada en un instante, es decir, por cada cien *tweets* generados en la red *Twitter* sólo 1 es emitido de manera pública a la API. Además, existe una restricción a la cantidad de elementos que pueden ser obtenidos en un intervalo de tiempo, luego de que este límite es alcanzado, se ha de esperar para volver a acceder a los datos del *stream*. Si se desea trabajar sin estas limitaciones, se puede hacer uso del llamado *FireHose* de *Twitter*, el cual entrega todo el flujo de eventos generados en la red sin limitaciones, sin embargo esta modalidad es de pago.

Por otro lado Valer (2011), señalan que la dificultad radica en el hecho de que cualquier persona puede realizar publicaciones en esta red social, induciendo ruido en la información (considerando el ruido como toda información que aparece junto a la deseada, pero no aporta nueva información), además de que, al ser publicaciones de máximo 140 caracteres, es complejo contextualizar el contenido.

CAPÍTULO 3. REQUERIMIENTOS

Este capítulo detalla los requisitos de las aplicaciones, descritos como historias de usuario. Estos señalan las necesidades de los clientes.

El cliente corresponde a miembros del equipo que lidera el proyecto FONDEF IDeA, código ID15I10560, proyecto orientado a generar herramientas para la gestión de desastres naturales. Los historias de usuario se levantan en reuniones con los investigadores y responsables de aplicaciones del proyecto donde se estipulan las funcionalidades deseables, dichas reuniones tuvieron lugar en el Departamento de Ingeniería informática de la Universidad de Santiago e Chile.

3.1 PROCESO DE TOMA DE REQUERIMIENTOS

La metodología en la que se basó el trabajo de este proyecto es la metodología *extreme programming* (XP), descrita anteriormente en la sección 1.5.1. En la presente sección se detalla el proceso de toma de requerimientos basados en esta metodología. La toma de requerimientos se realiza por medio de las llamadas historias de usuarios descritas por el cliente en las sucesivas reuniones de trabajo realizadas. El cliente, miembros del equipo FONDEF, poseían ya una visión clara del sistema en general, sin embargo al avanzar en el proyecto surgieron nuevos requerimientos que debieron ser abordados.

Dado el carácter iterativo de la metodología, se definió el siguiente ciclo de operación entre el equipo de desarrollo — el autor del presente trabajo — y los clientes:

- Los días miércoles de cada semana, se realiza una reunión en la oficina de los clientes donde se muestran los resultados del trabajo de la semana anterior. Esto corresponde a una iteración.
- En estas reuniones se entrega retroalimentación del trabajo realizado, señalando qué está bien y qué debiese ser modificado.
- Se plantean nuevas funcionalidades deseables.
- Al contrario de lo señalado por la metodología, no se realiza entrega del *software* generado en estas iteraciones, pues lo que se espera es el *software* final.

Las primeras cuatro iteraciones, correspondiente a las cuatro primeras semanas del proyecto, consistieron en *spikes* de investigación para entender, entre otras cosas, el funcionamiento de *Apache Storm*, procesamiento de información para ser categorizada, la captura de *tweets* desde la API y las herramientas para el uso de mapas.

Teniendo en consideración lo descrito anteriormente, ya desde el inicio se habían identificado algunas de las historias de usuario del sistema, estas eran: HU-c00, HU-c01, HU-v00, HU-v01 y HU-v03, correspondientes a su funcionamiento general y visualización.

El primer punto a ser construido la siguiente semana fue el apartado de comunicación (descrito en la sección 4.3.1), para ello se generó la historia de usuario HU-c04 en la que se añadió un sistema de persistencia al sistema. A partir de aquí se esbozó la arquitectura del sistema descrita en la sección 4.1, que fue incorporando componentes a medida que se identificaron las demás historias de usuario.

Con respecto al apartado visual, habiendo presentado las historias de usuario HU-v00, como un prototipo de la interfaz, HU-v01, como marcadores dentro del mapa y HU-v03, como un refresco de los marcadores almacenados cada cierto tiempo se solicitaron nuevos elementos para mejorar la experiencia del usuario, así se dio origen a la historia HU-v06, la cual trata sobre la aplicación de iconos descriptivos a los marcadores de cada categoría. Además se solicitó que la configuración con respecto a la HU-v03 fuese automática, para ello se escribió una nueva historia de usuario: HU-v08.

La semana siguiente se solicitó que existieran diferentes formas de visualización de marcadores; se pidió que, según el nivel de acercamiento del mapa, estos se agruparan formando *clusters* de marcadores que se agruparan según categoría dando origen a la historia HU-v02.

Producto de una charla realizada en la universidad donde se presentó una aplicación construida en la Universidad de Chile, referente a los efectos de desastres en redes sociales, se incorporó una nueva historia sobre una funcionalidad deseable para el sistema, la HU-v04, referente a la existencia de una línea de tiempo que mostrase la cantidad de eventos (necesidades), detectadas por fechas y que éstas pudiesen ser visualizadas en el mapa. Adicionalmente se señaló que era necesario un medio para que se incorporaran consultas al sistema, de manera de filtrar el flujo de datos de entrada según las necesidades de quien estuviese usando la aplicación, incorporando la HU-v05, además se señaló que se quería que el sistema mostrase estadísticas, sobre la actual consulta, referentes a la cantidad de eventos encontrados, procesados y usuarios, esto se agregó en la HU-v07.

La siguiente iteración se solicitó la implementación de un método que extendiera la consulta realizada por el usuario (HU-v05), según los datos que se hubiesen obtenido hasta el momento, para ello se gestó la historia de usuario HU-c02.

Finalmente el cliente solicitó un módulo para actualizar el modelo de clasificación utilizado, inicialmente se pidió que éste fuese automático, pero ante la dificultad técnica de ello, dado que la entrada para el modelo debe ser ingresada por un usuario experto, se sugirió a los clientes realizar un cambio e implementar un actualizador manual del modelo del clasificador, lo cual fue aceptado y se registró como HU-c03.

Es importante señalar que la historia de usuario HU-c00, correspondiente a la detección de necesidades en sí corresponde a la historia más compleja del sistema y está compuesta por la construcción de múltiples operadores que pueden desarrollándose a lo largo del proyecto, por lo que no era posible completarla en una iteración. Lo que se realizó fue presentar avances en la construcción de operadores semanalmente.

3.2 HISTORIAS DE USUARIO Y CRITERIOS DE ACEPTACIÓN

La sección 3.1 referenciaba, según lo descrito por la metodología *extreme programming*, las historias de usuario correspondientes a lo que se requiere para el proyecto. Estas historias de usuario están plasmadas en las Tablas 3.1 y 3.2, tienen la siguiente nomenclatura para su identificación: Aquellos que guarden relación con la aplicación de detección se identifican como 'HU-cXX', donde XX corresponde al número del requisito; 'HU-vYY' para aquellas que correspondan a la aplicación interfaz, donde, al igual que en el caso anterior, YY corresponden al número del requisito.

Tabla 3.1: Resumen de las HU ligadas al procesamiento.
Fuente: Elaboración Propia, (2016)

Identificador	Historia de usuario
HU-c00	Como cliente quiero capturar necesidades de la población en tiempo real cuando el país se encuentre en un escenario de catástrofe natural para poder contar con información para asistir a la población afectada.
HU-c01	Como cliente quiero que las necesidades detectadas se recojan desde la información generadas en redes sociales como Twitter, dado su caracter informativo.
HU-c02	Como cliente quiero que la búsqueda de necesidades pueda ser extendida automáticamente para encontrar información adicional que pueda ser de apoyo.
HU-c03	Como usuario deseo poder incluir diferentes modelos de clasificación dependiendo de las características del evento a analizar.
HU-c04	Como cliente quiero almacenar datos históricos para poder realizar análisis mas a fondo, incluso entre diferentes eventos.

Tabla 3.2: Resumen de las HU ligadas a la interfaz.
Fuente: Elaboración Propia, (2016)

Identificador	Historia de usuario
HU-v00	Como usuario quiero una interfaz basada en un mapa geográfico donde se pueda interactuar con la información generada.
HU-v01	Como cliente quiero que las necesidades detectadas puedan ser asociadas aun punto en un mapa geográfico para poder identificar el lugar físico de su fuente, esta ubicación debe ser de manera automática, incluso si no se cuenta con los datos de geoubicación.
HU-v02	Como usuario quiero que puedan aplicarse filtros a la visualización de los puntos de modo que según la distancia entre ellos, cuáles se quieran mostrar y el nivel de acercamiento que tenga el mapa se entreguen diferentes formas de mostrar la información para que la información se visualice con facilidad.
HU-v03	Como usuario quiero que la visualización de eventos se realice en tiempo real para tomar decisiones rápidas cuando la situación lo amerite.
HU-v04	Como usuario quiero visualizar eventos pasados, además quiero poder seleccionar un intervalo de tiempo y que el sistema muestre todos los eventos que se hayan detectado dentro de aquel intervalo de modo que pueda realizarse una análisis a posteriori de la emergencia.
HU-v05	Como usuario quiero poder especificar términos de búsqueda para acotar la búsqueda sólo a aquellos datos que contengan elementos relevantes para la situación a analizar.
HU-v06	Como usuario quiero que cada punto, correspondiente a una necesidad específica, tenga un diseño particular fácilmente identificable.
HU-v07	Como usuario quiero que sea posible visualizar estadísticas del procesamiento de la aplicación por consulta.
HU-v08	Como usuario quiero poder modificar cuánto tiempo se visualizará un evento antes de que sea considerado antiguo y cada cuánto tiempo se ha de añadir la información de los nuevos eventos.

Estas historias de usuario se corresponden con los criterios de aceptación descritos en las Tablas 3.3 y 3.4 que se presentan a continuación.

Tabla 3.3: Criterios de aceptación para HU de procesamiento.
Fuente: Elaboración Propia, (2016)

Identificador	Criterio de aceptación
HU-c00	<ul style="list-style-type: none"> · Debe construirse una topología para Storm capaz de detectar las necesidades. · Debe crearse un operador capaz de extraer información desde una fuente de datos basada en texto. · Debe almacenar informacion historica para una ventana de tiempo definida por el usuario. · Los elementos almacenados deben estar correctamente etiquetados.
HU-c01	<ul style="list-style-type: none"> · Twitter debe ser desde donde se obtienen los datos de entrada del sistema.
HU-c02	<ul style="list-style-type: none"> · Deben implementarse técnicas para realizar expansión de la consulta.
HU-c03	<ul style="list-style-type: none"> · El modelo de clasificación debe poder modificarse.
HU-c04	<ul style="list-style-type: none"> · Los datos deben estar almacenados en un repositorio local.

Tabla 3.4: Criterios de aceptación para HU de interfaz.
Fuente: Elaboración Propia, (2016)

Identificador	Criterio de aceptación
HU-v00	· Debe contarse con una interfaz que muestre los eventos detectados por el sistema.
HU-v01	· El mapa de eventos debe mostrar los eventos, asociados a un punto geográfico.
HU-v02	· Se debe poder filtrar por modos de agrupamiento. · Se debe poder filtrar por categorías. · El mapa debe permitir modificar su nivel de acercamiento.
HU-v03	· El mapa debe actualizarse automáticamente.
HU-v04	· Debe poder seleccionarse el intervalo. · Los eventos en el mapa deben modificarse según el intervalo que se seleccione. · Debe seleccionarse el intervalo mediante una línea de tiempo. · Debe mostrarse un histograma con los eventos pasados presentes en el sistema.
HU-v05	· Debe existir un lugar donde especificar estos términos. · El sistema debe mostrar qué términos se están utilizando para la búsqueda actual.
HU-v06	· Cada evento de categorización diferente debe tener un icono particular.
HU-v07	· Deben mostrarse la cantidad de usuarios diferentes que han emitido estados detectados. · Deben mostrarse la cantidad de necesidades detectadas. · Deben mostrarse la cantidad de eventos procesados.
HU-v08	· Debe existir un lugar donde realizar el cambio de parámetros. · Debe ser explícito el cambio de los parámetros de funcionamiento en la interfaz.

Estas historias fueron manejadas por el equipo de desarrollo como tarjetas dentro de un tablero Kanban, éste consiste en una pizarra, en este caso *online*, donde se separa el trabajo por columnas. Se utilizaron cuatro columnas:

- Por hacer: lista de todas las historias de usuario, divididas en tareas, que no se habían trabajado hasta ese punto del desarrollo.
- Haciendo: lista de las tareas que estaban en siendo desarrolladas actualmente.
- Por revisar: lista de las tareas finalizadas correspondientes a historias de usuario que no habían sido presentadas a los clientes aún.
- Hecho: lista de las tareas finalizadas que ya hubieran sido presentadas a los clientes y no generaran nuevos cambios.

Se utilizó, además, un sistema de colores para las tarjetas del tablero, donde el color verde correspondía a elementos del módulo de visualización; y amarillo correspondía a elementos del módulo de procesamiento. Adicionalmente existía el color rojo, el cual acompañaba a uno de los anteriores para señalar un *bug* en aquella tarea que debía ser corregido.

La Figura 3.1 presenta un ejemplo de lo anterior con la captura final del tablero Kanban realizado en la herramienta Trello.




Figura 3.1: Captura del estado final del tablero Kanban.
Fuente: Elaboración Propia, (2016)

CAPÍTULO 4. DISEÑO E IMPLEMENTACIÓN

El presente capítulo detalla la fase de diseño construcción de la aplicación, se señalan las decisiones tomadas a lo largo del desarrollo para cumplir con los requerimientos presentados en capítulo anterior.

Yendo desde lo general a lo particular se comienza presentando la arquitectura del sistema, construida a partir de los requerimientos establecidos en el capítulo anterior, posteriormente se analizan las decisiones que llevaron al diseño de dicha arquitectura.

4.1 ARQUITECTURA DEL SISTEMA

El sistema de detección de necesidades, en su conjunto, consta de dos módulos independientes: el *front-end*, dedicado a la interacción con el usuario, presentación de la información, etcétera; y el *back-end*, orientado a las tareas de procesamiento *online* de los datos para su posterior despliegue.

La comunicación entre los módulos se realiza por medio del almacenamiento de documentos en la base de datos. Esta arquitectura se presenta en la Figura 4.1. A continuación se detalla cada uno de los elementos que la componen.




Figura 4.1: Arquitectura del sistema.
Fuente: Elaboración Propia, (2016)

4.1.1 *Back-end*

El módulo de *back-end* corresponde al sistema de detección en sí, todo el sistema está alimentado por el *stream* entregado por la API de *Twitter*, pues en esta red social se generan más de 140 millones de *tweets* diariamente, Jones (2013), y que se dispara en periodos de crisis, Olteanu et al. (2015), por ello es considerada una fuente de información primaria, es decir, aquella que viene directamente de la población afectada. Haciendo uso de esta fuente de información da soporte a la historia de usuario HU-c02, que explicita el uso de ésta.

Para el procesamiento de los datos que llegan de forma continua se hace uso de *Apache Storm* para construir un grafo de procesamiento *ad-hoc* a la aplicación, capaz de detectar y categorizar todos aquellos eventos que respondan a los requerimientos de la aplicación. Para ello se utilizan los elementos de *Storm* presentados en la sección 2.2.2, *spout* y *bolt* para la construcción de operadores que realicen las tareas necesarias para la transformación de datos. Uno de estos operadores tiene que ver con cómo son compartidos los datos, en este caso, se hace uso de una base de datos no relacional, MongoDB, para compartir datos entre módulos para permitir una comunicación bidireccional, tanto de consultas como de elementos a ser desplegados en la visualización. Otro de los operadores tiene que ver con el etiquetado de datos, para ello se hace uso de un clasificador, almacenado como un archivo, generado haciendo uso de Mallet, McCallum (2002), para etiquetar las nuevas entradas como elementos de una categoría en particular. El cómo funcionan estos operadores se detalla a lo largo de éste capítulo.

Los elementos cuya comunicación se señala con una flecha roja son elementos que están considerados en la arquitectura final, pero que están fuera de los alcances de éste proyecto, ellos son: el sistema detector de eventos que, al detectar que se produce un evento catastrófico en el país, comienza a ejecutar el detector de necesidades; y el módulo etiquetador que recibe un archivo con entradas con eventos etiquetados, los cuales puede utilizarse para reentrenar el clasificador con el objetivo de mejorar su capacidad de clasificación.

4.1.2 *Front-end*

El módulo correspondiente a la visualización está encargado de desplegar la interfaz de usuario al sistema por medio de su navegador *web*. Hace uso de la información registrada por el módulo de detección de necesidades, la cual es almacenado en la base de datos, para mostrarla al usuario.

Para cumplir con las funcionalidad requeridas se hizo uso, por un lado, de la API de Google Maps para implementar una instancia de mapa en la aplicación. Haciendo esto se

cuenta con los llamados marcadores, correspondientes a puntos destacados en el mapa, los cuales corresponden, en este caso, a los eventos detectados a los que se les asigna, como es señalado en la HU-v06, una imagen para diferenciarles por categoría. Por otro lado, se hace uso de Highcharts, desde donde se obtienen tanto el histograma como la línea de tiempo para completar la historia de usuario HU-v04.

Además ésta aplicación proporciona el medio para que el usuario realice consultas al sistema para realizar un filtrado de datos que cumpla con sus necesidades, cumpliendo así con la historia de usuario HU-v05. De igual manera permite el establecimiento de parámetros para el funcionamiento de la aplicación como se especificó en la historia HU-v08.

4.2 CARACTERÍSTICAS DEL SISTEMA

A continuación se realiza mencionan las características que ha de tener el sistema, se hace esto para tener en cuenta en las decisiones tomadas en las siguientes secciones.

En primer lugar, es necesario hacer hincapié en el contexto en que el sistema opera. *Twitter* es un servicio que cuenta con millones de usuarios activos, los que generan constantemente nuevo contenido que recuperado por la API de *streaming*. Dado la masividad de los datos generados, se requiere de una plataforma de procesamiento capaz de lidiar con dicha carga y mantener tiempos de procesamiento razonables.

En segundo, y como se explicó en la sección 1.5.2, el funcionamiento interno de las aplicaciones construidas con *storm* se puede esquematizar por medio de un grafo dirigido donde los nodos se corresponden con los operadores definidos en la topología y que pueden tener diferente cantidad de elementos por procesar y tardar tiempos distintos en realizar su labor. Lo anterior sugiere que pueden existir niveles en los que se producen cuellos de botella en el *pipeline* de procesamiento. Considerando lo anteriormente expuesto el sistema ha de estar preparado para responder de la mejor forma posible cuando se produzcan estas obstrucciones en el proceso.

En tercer lugar, el uso de un clasificador de texto involucra que la calidad del etiquetado está dada por el cómo éste se construyó. La construcción está dada por los datos de entrenamiento; mientras más datos se entreguen, probablemente, la calidad del clasificador sea mayor. Esto quiere decir que el clasificador puede ser mejorado y que constituye una limitante el mantener éste estático.

4.3 DECISIONES DE DISEÑO

Esta sección presenta las decisiones tomadas por el autor al momento de diseñar las aplicaciones que componen el sistema de detección de necesidades.

4.3.1 Comunicación

Se ha de justificar lo expuesto hasta ahora al hacer mención de la existencia de dos módulos que componen el sistema de detección de necesidades.

El uso de *storm*, dificulta la integración de éste con un *framework* de desarrollo *web* para aplicaciones Java y, dado que el sistema ha de poseer una interfaz donde el usuario pueda manipular y visualizar la información presentada, se decidió dividir el sistema dos módulos separados: detección de eventos y visualización de la información.

En un primer momento se pensó comunicar ambos módulos por medio de peticiones REST cuyo contenido fuesen tanto las consultas ingresadas por el usuario para realizar una búsqueda más exhaustiva, como los datos correspondientes a marcadores ubicados en el mapa del visualizador, pero ésta aproximación no consideraba el trabajar con datos históricos, es decir, no requería de almacenamiento para los datos; al considerarla, la comunicación ya no se realiza por medio de peticiones REST, sino que se utiliza la base de datos como intermediario. La Figura 4.2 presenta cómo se produce la comunicación en el sistema.

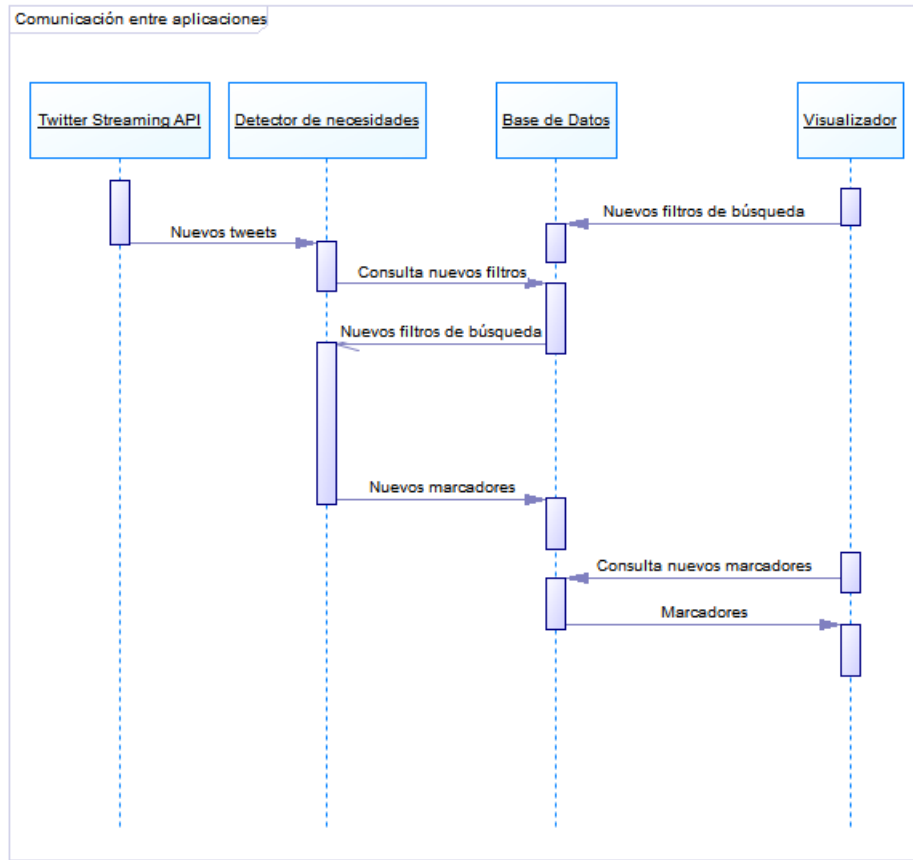


Figura 4.2: Esquema que representa la comunicación entre aplicaciones del sistema detector de necesidades.

Fuente: Elaboración Propia, (2016)

El módulo de detección comienza a alimentarse del *stream* de *Twitter* cuando el sistema es activado, posterior a ello, el módulo de detección realiza consultas a la base de datos buscando si es que el usuario ha hecho ingreso de nuevos términos para filtrar la información entrante. Paralelamente el módulo de visualización almacena, si son ingresados, los términos de búsqueda señalados por el usuario. Mientras tanto, el proceso de detección de necesidades continúa. Al concluir y obtener la respuesta, ésta es utilizada para generar nuevos marcadores, correspondiente a eventos donde se detectó una necesidad, los que pasan a ser almacenados en la base de datos. Periódicamente, el módulo de visualización realiza consultas a la base de datos, por medio de las cuales obtiene todos los nuevos marcadores generados desde la última consulta y los despliega en el mapa para que sean manipulados.

4.3.2 Persistencia

Si bien está decidida la implementación de un sistema de persistencia en la aplicación, no se ha definido cuál ha de ser el sistema de gestión de base de datos que se ha de utilizar, es por ello que en ésta sección se presenta la decisión tomada con respecto a este tema.

Debido a que se requiere mantener una ventana de datos históricos se requiere de un mecanismo de persistencia o base de datos. Los datos han de ser almacenados, al menos durante un tiempo, para que el sistema pueda realizar inferencias de información considerando los datos recibidos.

Se consideraron los principales sistemas de bases de datos utilizados y conocidos por el autor, dentro de los cuales se encontraban herramientas relacionales como: MySQL, PostgreSQL, SQL Server y MongoDB para el caso de sistemas de gestión de base de datos (DBMS) no relacionales. Dadas las características y las condiciones con las cuales opera el sistema de detección se requiere de un DBMS con rápido tiempo de respuesta en operaciones lectura/escritura; la decisión se tomó en base a los datos que se manejaban, pues no se apreció necesidad de implementar una modelo relacional, pues no habían datos que requirieran mantener la consistencia entre relaciones y, es más, se requiere, sobre todo, de rapidez. De esta forma y teniendo en cuenta los resultados presentados en pruebas empíricas realizadas por Macool (2013) en las cuales mostró que el tiempo de respuesta (en operaciones de lectura) es significativamente menor en MongoDB que en dos de los DBMS más conocidos como MySQL y PostgreSQL. Lo anterior, sumado al hecho de la capacidad de escalar de MongoDB reportada en fuentes oficiales o por diversos desarrolladores como Tobin (2016) que han compartido sus experiencias en la *web*, llevaron a decidir que MongoDB debiera ser el sistema de gestión de base de datos que se utilizase en el sistema.

Para realizar la conexión de MongoDB y el *framework* se utilizan dos bibliotecas: La primera corresponde a un ORM (Mapeo Objeto-Relacional), denominado Jongo, la cual hace uso de la segunda llamada Jackson, para realizar la conversión de JSON a objeto.

Volviendo a la historia de usuario que originó la necesidad de contar con un sistema de persistencia de datos, habiendo resuelto lo anterior la siguiente problemática que se presenta radica en qué información almacenar. Según la definición de la historia en la que se señalan "eventos pasados dentro de un intervalo de tiempo", se infiere que ha de guardarse tanto el contenido visible del dato, la clasificación que se le asignó y la fecha en que se identificó, para ello y dado que se seleccionó MongoDB, se especificó un esquema para los documentos de la colección, dados los datos que se almacenan sólo resta tener la información correspondiente a la ubicación, por lo que el esquema se definió como se presenta en la Figura 4.3 correspondiente a

la colección "Markers".

```
1. {  
2.   "_id": ObjectId("_MongoDB_ID"),  
3.   "contenido": "Contenido del tweet",  
4.   "categoría": "Categoría del tweet",  
5.   "latitud": "Coordenada Latitud",  
6.   "longitud": "Coordenada Longitud",  
7.   "generatedAt": ISODate("YYYY-mm-ddTHH:mm:ssZ")  
8.  
9. }
```

Figura 4.3: Ejemplo de documento en la colección Markers.
Fuente: Elaboración Propia, (2016)

El primer campo corresponde al ID asignado por mongo para cumplir con la unicidad de los datos, el segundo campo corresponde al contenido textual del *tweet* para ser mostrado junto con el marcador y que el usuario pueda ver desde dónde el sistema asignó aquel *tweet* a una categoría en particular. El tercer campo corresponde al nombre de la etiqueta o categoría asignada al *tweet*, esta asignación está dada por el resultado de la evaluación del clasificador. Los campos cuarto y quinto corresponden a la ubicación geográfica en la que se posiciona el marcador y, finalmente, el sexto campo corresponde al momento en que fue creado el marcador para ser utilizado en los diferentes criterios de visualización del sistema.

4.3.3 Sistema de procesamiento

Ya se mencionó que se seleccionó storm para construir el detector de necesidades, pero no se ha especificado el porqué de ello. Por este motivo en los siguientes párrafos se exponen las razones por las cuales se tomó esta decisión.

Dado el contexto del funcionamiento del sistema, éste ha de entregar respuestas rápidas ante una emergencia; para ello, y como es descrito en la historia de usuario HU-c00, se requiere de un sistema capaz de procesar eventos en tiempo real que, dado la masividad de datos con los que debe lidiar la aplicación, ésta ha de poder escalar. El problema en este punto es el cómo construir un sistema capaz de identificar necesidades y que posea esta propiedad.

Se consideraron sistemas de procesamiento distribuido *Apache S4*, *Apache Storm* y *Apache Spark*; estos sistemas tienen la particularidad de poder trabajar con múltiple máquinas. En un inicio se consideraron tres plataformas sobre las cuales puede construirse un sistema que pudiese cumplir con lo solicitado.

Apache S4, pese a su simplicidad, no continuó con su desarrollo luego del año 2013 y nunca tuvo una versión estable 1.0, razones por las cuales se dejó como segunda opción. Apache Spark, pese a contar con continuos *releases*, una comunidad de desarrolladores no menor y permitir la elaboración de sistemas escalables no era lo que se buscaba en aquel momento como herramienta de desarrollo, pues está orientado al procesamiento por lotes y no en tiempo real. Al momento de consultar con los clientes, estos esperaban que el sistema, internamente, se comportara según el paradigma de procesamiento de *streams*, por medio de operadores dispuestos en un grafo. Por ello finalmente se optó por *Apache Storm*.

Storm permite construir sistemas que cumplan con las características de un sistema distribuido, como lo son: escalabilidad (tanto horizontal como vertical) y tolerancia a fallos (como la capacidad de un sistema para realizar correctamente y en todo momento aquello para lo que fue diseñado). Estos sistemas están compuestos por dos tipos de elementos: *Spout* y *Bolt*, que fueron descritos en el Capítulo 2. Al combinar esos elementos se da origen a un grafo dirigido, como el presentado en la Figura 2.3 en la página 20, donde cada elemento de procesamiento (*bolt*), cumple con una determinada tarea utilizando como entrada la salida del elemento anterior.

4.3.4 Fuente de datos

La historia de usuario HU-c01 refleja desde dónde se han de obtener los datos, pero es necesario especificar más aún. Como se señaló al momento de definir los alcances de este trabajo, sólo se utiliza *Twitter* como fuente de información, así la unidad de información pasa, desde ahora, a llamarse como se habitúa en aquella red social: el *Tweet*.

Existen tres tipos de *streaming endpoints* disponibles, cada uno para un caso de uso particular y son descritos en la Tabla 4.1.

Tabla 4.1: *Streaming endpoints* de *Twitter*.

Fuente: Elaboración Propia, (2016)

Público	Stream del que fluye la información pública de Twitter. Casos de uso: Seguimiento de usuarios o tópicos específicos o minería de datos.
Usuario	Flujo que toda la información correspondiente a un usuario.
Sitio	Versión multi-usuario de la anterior.

Para esta aplicación la adecuada corresponde a la API pública. En ésta, a la vez, existen dos puntos de acceso; el público y *firehose*. El acceso público es gratuito y permite el acceso a un 1% de la información que se genera en tiempo real y para acceder a él basta con crear una aplicación dentro de *Twitter*. En cambio para acceder a *firehose*, el cual permite acceso total a la información, debe comprarse el acceso. Dadas estas condiciones se seleccionó, previo

acuerdo con los clientes, el uso de la API pública.

Para hacer uso de la API descrita con anterioridad es necesario obtener cuatro claves de acceso: *Access Token*, *Access Token Secret*, *Consumer Key (API Key)* y *Consumer Secret (API Secret)*. Para más información sobre cómo conseguir estas claves consulte el Apéndice B.

4.3.5 Términos de búsqueda

Twitter4J, es una herramienta que permite obtener el flujo de información desde *Twitter* implementa una forma de filtrado mediante el uso de palabras clave, pero posee una limitante al momento de modificar la búsqueda, deben instanciarse nuevamente los objetos con los cuales se realiza la conexión a la API de *Twitter*, eso se traduce en tiempo de procesamiento perdido. Para solucionar este inconveniente se decidió implementar un operador, descrito en la sección 4.4.2, el cual está encargado de realizar el filtrado de acuerdo a términos y llevar a cabo la operaciones descritas en la sección 4.4.2 referente a la expansión de la consulta. Sin embargo, un operador como este puede poseer réplicas que operan al mismo tiempo, con esto surge el problema de ¿Cómo comunicar y aplicar los nuevos términos de búsqueda, desechando los antiguos?.

Para dar solución a esta problemática se decidió recurrir a la base de datos; almacenar la consulta y asignar un estado para controlar el comportamiento del operador. Así el esquema en la base de datos queda tal y como se presenta en la Figura 4.4, documento de la colección "Queries".

```
1. {  
2.   "_id": ObjectId("MongoDB_ID"),  
3.   "terminos": [  
4.     "término A",  
5.     "término B"  
6.   ],  
7.   "estado": "Estado",  
8.   "generatedAt": ISODate("YYYY-mm-ddTHH:mm:ssZ")  
9. }
```

Figura 4.4: Ejemplo de documento en la colección queries.

Fuente: Elaboración Propia, (2016)

Donde la propiedad "estado" puede tomar dos valores: "actual" o "antiguo", reflejan si una consulta se está llevando a cabo o no. Estos valores son asignados por la aplicación responsable de la interfaz la responsable de recibir los términos de búsqueda por parte del usuario.

Para implementar este operador se utilizaron dos clases llamadas *Current-*

QueryChecker y *QueryExpander* desarrolladas, la primera, para detectar cuándo y si es que ha cambiado una consulta en la base de datos y la segunda para desarrollar la labor descrita por el algoritmo de expansión descrito en la sección 4.4.2.

4.3.6 Categorización de necesidades

La definición de las categorías es un punto importante dentro de la construcción de la aplicación. Teóricamente en función a la cantidad de clases (categorías), el tamaño del conjunto de entrenamiento ha de ser mayor o menor.

Inicialmente se consideró la taxonomía definida por Olteanu et al. (2015), pero el equipo del proyecto FONDEF IDeA estableció que no era conveniente utilizar, pues presentaba gran cantidad de categorías y era demasiado específica. Como alternativa se sugirió en su lugar utilizar la clasificación realizada por Hidalgo & Rosas (2014), en la que se presentaba una categorización de cinco categorías. Éstas fueron realizadas por parte de un equipo de psicólogos expertos en el contexto del proyecto PMI-USA 1204, basándose en la información obtenida del terremoto de febrero de 2010 y los *tweets* recolectados en dicho evento, éstas eran:

1. Necesidades básicas: *Tweet* que entregue o solicite información sobre servicios básicos: Agua potable, electricidad y abastecimiento de alimentos.
2. Comunicación: *Tweet* que entregue o solicite información sobre alguna localidad.
3. Seguridad: *Tweet* que señale un riesgo para la población.
4. Personas: *Tweet* que haga referencia al hallazgo o búsqueda de una persona desaparecida.
5. Irrelevante: Cualquier otro *tweet*.

Acordando con el equipo, se decidió separar el primer ítem en los tres elementos que lo componen: Agua, alimentos y electricidad. Así, finalmente, se obtienen siete categorías de clasificación.

Los elementos clasificados como "Irrelevantes" no se muestran en el mapa de eventos, pues hacen referencia a eventos que, pese a haber pasado por todos los operadores anteriormente descritos, no guardan relación con el evento o sus consecuencias. Estos pueden ser *tweets* a etiquetar por expertos *a posteriori* con el objetivo de enriquecer la información del clasificador. Esta tarea, sin embargo, está fuera del alcance de este proyecto.

4.3.7 Clasificador

Se busca generar un clasificador automático capaz de detectar necesidades y lidiar con la jerga nacional. Para ello, según lo descrito por Manning et al. (2008) en su libro *Introduction to Information Retrival*, se entrenó un clasificador basado en *Naïve Bayes*, haciendo uso de Mallet, pues en pruebas realizadas con las RapidMiner y Weka, mencionadas en la sección 2.1.2, alcanzó mejores resultados.

La sección 4.2 ya hace referencia a la inconveniencia de utilizar un clasificador estático para el etiquetado de nuevos eventos, al tratarse de un aprendizaje supervisado, donde se requiere de una persona entregue la respuesta esperada para realizar el entrenamiento, no es posible realizar este proceso de manera automática.

Al no poder automatizar el proceso antes señalado se consultó con el equipo del proyecto FONDEF IDeA si es que era factible la implementación de un actualizador manual del clasificador, lo cual fue aceptado.

Segun la metodología KDD, los pasos que se siguen para construir un nuevo clasificador son los siguientes:

Los datos son seleccionados por el usuario, estos datos se agruparan en un archivo de texto, un archivo CSV en el cual los elementos se separaran utilizando el caracter punto y coma (;). El formato que se utiliza para el archivo de entrada se muestra en la Figura 4.5 , así cualquier archivo que cumpla con el formato permite la creación de un nuevo modelo clasificador.

Identificador	Etiqueta	Contenido
1	2	3

Figura 4.5: Formato archivo de entrada.
Fuente: Elaboración Propia, (2016)

1. Corresponde a un identificador arbitrario, pero necesario para la herramienta de clasificación Mallet.
2. Corresponde a la etiqueta que categoriza al contenido.
3. Contenido del *tweet* propiamente tal.

El preprocesamiento y transformación de los datos está dado por la definición de los operadores presentados en la sección 4.4.2.

Teniendo en consideración que se utilizan dos aplicaciones distintas, donde en una se construye el clasificador y en otra donde es utilizado. Surge el problema de cómo realizar la

comunicación entre ellas. Para solucionar este inconveniente se utiliza una carpeta compartida por ambas aplicaciones. En el caso de sistemas Unix se utiliza el directorio `/opt/DeNe`, mientras que para Windows se utiliza `C : /DeNe/`. En estos directorios se almacena un fichero con el clasificador serializado.




Figura 4.6: Fichero clasificador en `C : /DeNe/`.
Fuente: Elaboración Propia, (2016)

Cada vez que se actualice el clasificador se contrasta el nuevo con el ya existente, de encontrar mayor precisión en el primero, se reemplaza en la carpeta antes mencionada, según el sistema operativo de la máquina que se esté utilizando. En caso contrario, se mantiene al anterior. En ambos escenarios se le da a conocer al usuario la precisión de ambos.

4.3.8 Interfaz web

Teniendo en consideración la característica del desarrollo de esta aplicación como un proyecto ágil con un mínimo de personal de desarrollo se requería de un *framework* que contribuyera a acelerar la construcción de la aplicación. Tras considerar las alternativas más conocidas como *Spring*, *Hibernate* o *JSF* que tienen una curva de aprendizaje elevada, se optó por utilizar un cuarto *framework* que aunque desconocido, promete una simplicidad en su uso. *Play Framework*, construido haciendo uso de Scala y Java permite construir aplicaciones ligeras (tamaño en disco), sin estado (no guarda configuraciones de una sesión para ser utilizadas luego) y por defecto RESTful, ideal para la comunicación entre aplicaciones. Éste *framework* sigue el patrón de arquitectura Modelo-vista-controlador (MVC). Cuenta con un compilador en tiempo real (compila y realiza el despliegue de la aplicación cuando detecta un cambio en el código), lo que agiliza en gran medida el desarrollo, pues al automatizar este proceso mantiene la atención en lo que se está desarrollando.

Para visualizar los puntos encontrados por el detector de necesidades se decidió utilizar la API de *Google Maps* la que permite la colocación de los denominados 'marcadores' en un punto específico del mapa y asociar a ellos algún tipo de información. Así, aunque el funcionamiento interno esté dirigido por *Play*, la principal funcionalidad del sistema, mostrar el mapa con sus marcadores, es implementada utilizando Javascript.

Estos marcadores, ya ubicados en el mapa, tienen asociado un cuadro de texto dentro del cual refleja el la categoría a la que pertenece y el *tweet* original, el texto, que lo generó, la Figura 4.7 presenta un ejemplo del funcionamiento de esto en la interfaz *web*. Esto tiene como objetivo permitir decidir, en última instancia, al usuario si ha sido correctamente clasificado.



Figura 4.7: Ejemplo de marcador en el mapa con su categorización y *tweet* que lo generó.
Fuente: Elaboración Propia, (2016)

Según lo solicitado en la historia de usuario HU-v02 se prepararon dos tipos de filtros a la interfaz para la visualización de eventos en el mapa: El primero considera el agrupamiento o *clustering* de marcadores, mientras que el segundo considera el tipo de marcador o marcadores que se desean visualizar.

Para el caso del agrupamiento se definieron tres modos de funcionamiento las cuales se describen a continuación:

1. No agrupar: Mostrar todos los marcadores que correspondan en el mapa de acuerdo al punto geográfico que corresponda en su definición.
2. Agrupar por distancia: Define una grilla invisible en el mapa donde los elementos que calcen en una cuadrícula son agregados a un *cluster* y visualizados como tal.
3. Agrupar por categoría: De igual forma que el agrupamiento por distancia, pero sólo agrega elementos que comparen categoría.

La Figura 4.8 presentan un ejemplo de ambos tipos de agrupamiento especial, respectivamente por distancia y categoría.

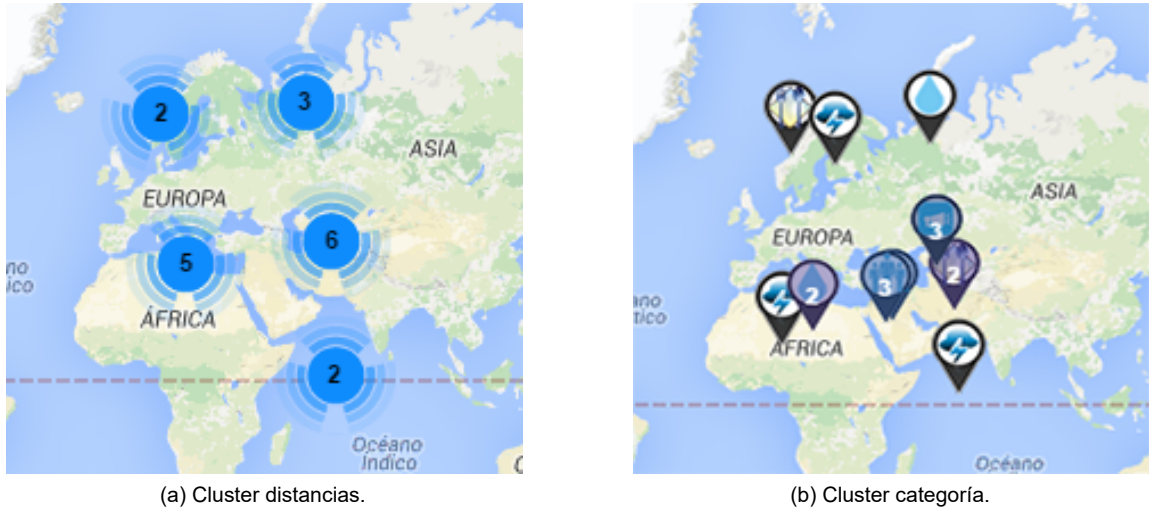


Figura 4.8: Ejemplos de agrupamiento basados en distancia y categorías.
Fuente: Elaboración Propia, (2016)

Para el segundo caso sólo se definieron dos reglas de funcionamiento las cuales se describen a continuación:

1. Mostrar todos: Muestra elementos de todas las categorías existentes.
2. Mostrar categoría: Para cada categoría mostrar sólo los elementos de aquella categoría.

Al combinar ambos tipos de filtros se tienen potencialmente seis modos de funcionamiento, pero considerando las categorías descritas en la sección 4.3.6 ese número se expande a veintinueve modos de funcionamiento del visualizador.

4.4 IMPLEMENTACIÓN DEL SISTEMA

En la presente sección se detalla el proceso de implementación de la solución diseñada. Para ello se trabaja en paralelo en el desarrollo de ambos módulos: *front-end* y *back-end* bajo la metodología XP, donde se generan versiones sucesivas de la solución, las cuales fueron evolucionando de acuerdo a los requerimientos del cliente.

4.4.1 *Front-end*

La implementación del visualizador de eventos se realizó haciendo uso del *framework* de Java *Play*, éste *framework*, por defecto, crea aplicaciones que siguen el patrón de diseño MVC,

por lo tanto se tienen tres niveles dentro de la aplicación:

- Modelo: donde están los elementos que permiten interactuar con la base de datos.
- Controlador: presentando los métodos de reacción ante los eventos detonados en el nivel de presentación.
- Vista o presentación: muestra las interfaces *web* diseñadas para que el usuario interactúe con el sistema.

Filtrado de marcadores

Dentro del nivel de presentación se encuentra el mapa, proporcionado por la API de Google Maps como se mencionó en la sección 4.3.8. Allí, también, se señaló que existen filtros para la visualización de eventos de manera que se la presentación de estos se apegue a las necesidades del usuario. Para implementar estos filtros, internamente, la aplicación hace uso de $n + 1$ *clusters*, donde n corresponde al al número de categorías y el cluster extra es para agruparlos a todos. Así, en el caso de querer ver los eventos agrupados, y dependiendo si se quiere o no agruparlos sin discriminación de categoría, se llenan los *clusters* pertenecientes a la visualización general o a la visualización por categoría. Para el caso de querer mostrar sólo una categoría en particular, sólo se permite que los *cluster* se llenen con los elementos de la categoría seleccionada.

Lo anteriormente descrito es presentado a continuación en el Algoritmo 4.1 para facilitar la comprensión de la lógica interna de los filtros presentados.

Para realizar la selección del intervalo mencionado en la HU-v04 se solicitó, por parte del equipo FONDEF IDeA, el uso de una línea de tiempo con intervalo deslizante que, además, mostrase la cantidad de eventos detectados por fecha por medio de un histograma. Para ello se utilizó, inicialmente, se utilizó *JDateRangeSlider*, de la biblioteca Javascript *JQRangeSlider*, Gautreau (2010). Ésta biblioteca era suficiente para seleccionar el intervalo de fechas y detectar cambios producidos en la línea de tiempo para actualizar los valores, mas no permite la implementación de un histograma externo.



Figura 4.9: Selectorde fechas JDateRangeSlider.
Fuente: Gautreau (2010)

Algoritmo 4.1: Algoritmos de utilización de filtros

Entrada: Tipo de agrupamiento A .

Entrada: Discriminador de categoría K .

Entrada: Marcadores M .

Lista de marcadores L .

Clusters de marcadores $C = \{c_0, \dots, c_{n+1}\}$.

Para cada m_i perteneciente a M **Hacer:**

Si la categoría de m_i no es "irrelevante" y la categoría de m_i es igual a K **entonces:**

añadir el marcador a L .

Sino: Si K es "todas las categorías" **entonces:**

añadir el marcador a L .

Fin Si

Fin Para

Si A es "no agrupar" **entonces:**

Para cada l_i perteneciente a L **Hacer:**

posicionar l_i en el mapa.

Fin Para

Sino: Si A es "agrupar todos" **entonces:**

Para cada l_i perteneciente a L **Hacer:**

añadir l_i al clister c_0 .

Fin Para

posicionar c_0 en el mapa.

Sino:

Para cada l_i perteneciente a L **Hacer:**

añadir l_i al cluster c_{i+1}

Fin Para

Para cada c_i perteneciente a $C - \{c_0\}$ **Hacer:**

añadir l_i al cluster c_i

Fin Para

Fin Si

Para lograr implementar ambas, línea de tiempo e histograma, se utilizó una biblioteca Javascript distinta. La Figura 4.11 presenta la implementación utilizando *HighCharts*, Hønsi & Hjetland (2006). Ésta, al contrario de *JQRangeSlider*, no permitía capturar los cambios en el histograma. Para solucionar este inconveniente se implementó una función javascript que recogiese los valores del intervalo y arrojase un evento cuando se produce un cambio, este

evento se asoció al eje x de la línea temporal, cambiando el valor de la variable *valuesOfAxis* cada vez que se moviese el eje, éste evento es descrito en la Figura 4.10.

```

1. xAxis: {
2.     events: {
3.         setExtremes: function (e) {
4.             valuesOfAxis[0] = Highcharts.dateFormat(null, e.min);
5.             valuesOfAxis[1] = Highcharts.dateFormat(null, e.max);
6.             $('#histograma2').trigger('change');
7.         }
8.     }
9. }

```

Figura 4.10: Implementación de evento de detección de cambios en la línea temporal.
Fuente: Elaboración Propia, (2016)

Inicialmente este histograma sólo está disponible en inglés, pero permite cambiar todas sus etiquetas manualmente, así, para mejorar la usabilidad de la aplicación se modificaron todos los textos para estuviesen en español. El resultado de esta modificación es presentado en visible en la Figura 4.11.




Figura 4.11: Selector de fechas presente en la aplicación.
Fuente: Elaboración Propia, (2016)

Tras la selección de intervalo dentro del cual se desea que el sistema muestre los estados recibidos, se implementó un servicio REST, donde mediante una consulta del tipo POST con parámetros fecha inicial y final, retornase una lista con todos los marcadores encontrados.

Las categorías mencionadas a continuación son descritas en la sección 4.3.6, corresponden a las definidas por Hidalgo & Rosas (2014). Los iconos correspondientes a las categorías que soporta el programa se definieron mediante la combinación de dos imágenes para cada categoría: un marcador de mapa, similar a los definidos en la API de Google Maps y una que sugiriera al usuario la categoría a la que hace referenciar. Los diseños finales son presentados en la Figura 4.12



Figura 4.12: Iconos de categorías para marcadores.

Fuente: Elaboración Propia, (2016)

Se consideró apropiado, además, diseñar un icono que representara la densidad de marcadores al momento de realizar el agrupamiento por categorías descrito en ésta sección para ello y siguiendo la combinación de colores utilizada por la biblioteca *MarkerClusterer*, Inc (2014), donde se muestra un cluster azul cuando es un cluster pequeño; amarillo para uno medio y rojo para uno grande. El tamaño de cada uno de estos es especificado internamente por la biblioteca:

- Azul: De dos a diez elementos.
- Amarillo: De once a cien elementos amarillo.
- Rojo: Desde cien elementos.

Se prepararon, entonces, tres iconos adicionales a cada categoría para reemplazar los íconos por defecto de la biblioteca, las que pueden verse en las Figuras 4.13. a la 4.18.



Figura 4.13: Iconos de cluster para categoría agua.

Fuente: Elaboración Propia, (2016)



Figura 4.14: Iconos de cluster para categoría alimento.

Fuente: Elaboración Propia, (2016)



Figura 4.15: Iconos de cluster para categoría electricidad.
Fuente: Elaboración Propia, (2016)



Figura 4.16: Iconos de cluster para categoría comunicación.
Fuente: Elaboración Propia, (2016)



Figura 4.17: Iconos de cluster para categoría personas.
Fuente: Elaboración Propia, (2016)



Figura 4.18: Iconos de cluster para categoría seguridad.
Fuente: Elaboración Propia, (2016)

Dado que se solicitó que la interfaz no se recargue cada vez que se produzca un cambio dado por un nuevo evento detectado o la modificación en el intervalo de visualización, se utilizador las tecnologías Javascript y AJAX para capturar los cambios en la línea temporal al momento de su ocurrencia, descrita en esta sección. Cada vez que se detecte un cambio, se elimina todo marcador del mapa y se reubican en el todos los que cumplan con los parámetros de búsqueda.

Estadísticas de procesamiento

Específicamente se solicitaron tres tipos de estadísticas que han de ser mostradas por consulta, estas se definen a continuación:

1. Cantidad de eventos detectados, es decir, *tweets* que fueron clasificados.
2. Cantidad de usuarios distintos identificados en aquellos eventos.
3. Cantidad total de *tweets* que han pasado por el sistema desde el inicio de la consulta actual.

Para cumplir lo solicitado se necesitaba añadir elementos no considerados en la base de datos; hace falta conocer al usuario y contar los *tweets* ingresados desde *Twitter4J*.

Para completar esta historia se realizaron modificaciones al esquema previamente definido en la sección 4.3.2, este de por sí era suficiente para cumplir con la estadística número uno, pero incapaz de realizar las otras dos. Para la segunda estadística se consideró que bastaba con guardar al usuario junto con la colección de marcadores. De acuerdo a Dev.twitter.com (2016) en su sección F. *Be a Good Partner to Twitter*, se insta a los desarrolladores que almacenen contenido *offline* de *Twitter*, a almacenar sólo el ID del usuario o del *tweet*, por ello y siguiendo estos lineamientos se agrega el campo "userID" al esquema marcadores, pasando a quedar como se aprecia en la Figura 4.19.

```
1. {  
2.   "_id": objectID("_MongoDB_ID"),  
3.   "contenido": "Contenido del tweet",  
4.   "categoría": "Categoría del tweet",  
5.   "latitud": "Coordenada Latitud",  
6.   "longitud": "Coordenada Longitud",  
7.   "userID": "Identificación del usuario en Twitter",  
8.   "generatedAt": ISODate("YYYY-mm-ddTHH:mm:ssZ")  
9. }
```

Figura 4.19: Ejemplo de documento en la colección Markers.
Fuente: Elaboración Propia, (2016)

Para la tercera estadística la colección de marcadores no sería útil, pues no refleja la cantidad de tweets procesados, para ello es necesario implementar una tercera colección de documentos en la base de datos y almacenarlos antes de la aplicación de cualquier tipo de filtro. Esta colección tiene el esquema presente en la Figura 4.20.

```

1. {
2.   "_id": ObjectId("MongoDB_ID"),
3.   "tweetText": "Contenido del Tweet",
4.   "timestamp": ISODate("YYYY-mm-ddTHH:mm:ssZ")
5. }

```

Figura 4.20: Ejemplo de documento en la colección Status.
Fuente: Elaboración Propia, (2016)

Al almacenar sólo el contenido del texto no viola las políticas de uso descritas de *Twitter*, sólo es necesario la fecha para la estadística realizar la estadística, pero resulta útil almacenar el contenido para realizar la expansión de la consulta descrita en la sección 4.4.2 y no aumentar la latencia almacenando el ID y realizando una nueva consulta a la API de *Twitter*.

En general la obtención de estas estadísticas se realiza utilizando el Algoritmo 4.2 descrito a continuación.

Algoritmo 4.2: Algoritmos de generación de primera y tercera estadística.

Entrada: Colección c

Entrada: Fecha de la consulta actual f

Salida: Contador de eventos $counter$

$counter = 0$

Para Documento d_i en la colección c **Hacer:**

Si fecha de d_i es posterior a f **entonces:**

$counter = counter + 1$

Fin Si

Fin Para

Retornar $counter$

Este algoritmo, como se mencionó, es de uso general y permite cumplir tanto la primera como la tercera estadística, para el caso de la segunda se requiere una modificación, pues se solicitó conocer los usuarios diferentes, el algoritmo 4.3 presenta el algoritmo modificado para la segunda estadística.

Algoritmo 4.3: Algoritmos de generación de segunda estadísticas.

Entrada: Colección c

Entrada: Fecha de la consulta actual f

Salida: Lista de usuarios vacía $list$

Para Documento d_i en la colección c **Hacer:**

Si fecha de d_i es posterior a f **entonces:**

Si ID del usuario de d_i no está en $list$ o $list$ es vacía **entonces:**

Añadir d_i a $list$

Fin Si

Fin Si

Fin Para

Retornar Cantidad de elementos en $list$

Lo anteriormente descrito aún no es suficiente para mostrar las estadísticas solicitadas; hace falta un medio para comunicar los nuevos datos al *front-end* de la aplicación, de manera que estos sean mostrados o actualizados. Para ello se utiliza el mismo principio utilizado para la actualización de los marcadores, en donde cada cierto tiempo se consulta a la base de datos por nuevos marcadores. Para el caso de las estadísticas se implementó un servicio de consulta del tipo GET para obtener, mediante AJAX, el valor del resultado de la implementación de los algoritmos expuestos anteriormente.

Configuración

La necesidad de un segmento de configuración nace producto de la HU-v01. El visualizador de eventos tiene dos maneras de comportarse:

- Modo tiempo real: Cuando el sistema esté en funcionamiento y cada cierto tiempo, t_1 , se actualizan los marcadores de los nuevos eventos y estos se muestran durante un tiempo, t_2 .
- Modo línea de tiempo: Funcionamiento basado en lo descrito en HU-v04.

Los tiempos t_1 y t_2 , inicialmente fueron decididos de manera arbitraria, pero al mostrar su funcionamiento se sugirió que estos parámetros pudiesen ser definidos por el usuario, por ello, se implementó una sección de configuración dentro de la aplicación de visualización para permitir la definición de estos valores. La importancia de la definición de estos valores viene dada por las necesidades del usuario, pero traen consecuencias al sistema.

Para el primer caso, un menor t_1 implica que se realizan más consultas al sistemas, pese a esto, es adecuado un valor pequeño cuando se encuentre en operación y el sistema de

detección esté generando contenido constantemente. Para la operación en periodos normales, es decir, cuando no esté ocurriendo un evento del tipo desastre, la generación de eventos será nula o muy baja, en esas ocasiones es recomendable un t_1 elevado.

Para el caso del tiempo t_2 , estará definido por el tiempo que el usuario estime que un evento está vigente, su valor no afecta de gran manera al sistema, pues sólo tiene fines visuales, descartando eventos que no cumplan con la ventana de tiempo $Tiempoactual - tiempodecreacin \geq t_2$, a mayor t_2 , mayor es la ventana de tiempo en la que un evento se considera vigente.

4.4.2 Back-end

El detector de necesidades se implementa utilizando un motor de procesamiento de *stream*, en este caso *Storm*. La implementación de *Storm* requiere de la definición de una topología de grafo compuesta por operadores que realizan tareas y comparten eventos. Para implementar el detector se requirió de la construcción de operadores especializados capaces de realizar alguna de las tareas necesarias para detectar las necesidades expresadas en el texto. A continuación, en esta sección, se presenta la construcción de estos operadores.

Operador fuente de datos

Este operador es el encargado de conectarse con la fuente de datos, en este caso la API de *Twitter*, y comunicar los eventos resto del sistema de procesamiento de *stream*. En el caso particular de *Storm*, este operador corresponde a un *spout*.

Conociendo desde donde se obtiene la información y teniendo acceso a ella resta conocer cómo realizar la conexión. Para ello se decidió utilizar *Twitter4J*, una biblioteca no oficial de Java para las API de *Twitter*. Para su funcionamiento sólo requiere del uso de Java en su versión 5 o superior.

La implementación de lo anteriormente descrito se realiza utilizando una instancia del objeto *TwitterStream*, el cual captura el flujo público de *Twitter*, almacenando cada estado recibido en una cola. Con esto en mente se construyó el primer operador del sistema correspondiente al *Spout* que surte de datos al sistema.


```

1.  @Override
2.  public void nextTuple() {
3.      //Mientras la cola no esté vacía: Busy waiting.
4.      while(queue.isEmpty()){
5.          Utils.sleep(50);
6.      }
7.      Status status = queue.poll();
8.
9.      if (status == null) {
10.         Utils.sleep(50);
11.     } else {
12.         /*
13.          *  Guarde los ID y fecha de recepción del estado,
14.          *  Luego emite a la topología.
15.          */
16.         statusPersistence.saveStatus(status);
17.         _collector.emit(new Values(status));
18.     }
19. }

```

Figura 4.21: Implementación del *Spout* del sistema.

Fuente: Elaboración Propia, (2016)

Considerando lo recién expuesto la Figura 4.21 muestra cómo los estados son emitidos por el *spout* al sistema basándose en la cola (*queue*) para manejar lo que llega desde el *stream*. Al ser llamado por parte de *Storm*, el método *nextTuple*, espera a que la cola de eventos no esté vacía y, cuando esto se cumple, toma un *tweet* (*status*), y lo emite al sistema, no sin antes almacenar su ID e ID de usuario para los fines estadísticos.

Operador idioma

Un primer desafío en el proceso de clasificación radica en la detección de idioma. En el presente trabajo nos enfocamos en la detección de necesidades en español. De acuerdo a Statista (2016), existen actualmente 310 millones de usuarios activos en *Twitter* (a enero del 2016), de los cuales 65 millones pertenecen a los Estados Unidos, cuyo idioma oficial es el inglés, según Smith (2016), y se estima que este año, en latinoamérica, Brasil, cuyo idioma oficial es el portugués, alcance los 15 millones de usuarios según eMarketer (2015), sin considerar países árabes o asiáticos podemos deducir, al menos, un 30% de los usuarios activos de *Twitter* hablan idiomas distintos al español, al menos, oficialmente. Dado que el sistema está pensado para operar dentro de Chile donde el idioma oficial es el español, se hace necesario filtrar todos aquellos *tweets* que estén escritos en un idioma distinto al español. Este operador de filtrado debe ser ubicado luego del *spout*, dado que todo evento que no cumpla esta condición no es de interés

para la aplicación, de esta manera se evita procesar eventos que no aportan información para el sistema.

Nakatani (2010) desarrolló, haciendo uso de un clasificador *Naïve Bayes*, un módulo escrito en Java el cual es capaz de detectar con éxito 49 idiomas dentro del texto con un 99.8% de precisión. Sin embargo la ejecución de este detector es costosa, razón por la cual se decidió implementar la selección de idioma con un mecanismo de filtrado basado los metadatos del *tweet*, donde, precisamente uno corresponde al idioma de éste. Si bien no es del todo preciso, el costo de selección es bajo y en pruebas realizadas se demostró que es capaz de filtrar de manera correcta un alto porcentaje de los mensajes.

La Figura 4.22 presenta el código de la implementación de este *bolt*, correspondiente a su método *execute*, descrito en la sección 1.5.2.

```
1. @Override
2. public void execute(Tuple tuple) {
3.     Status status = (Status) tuple.getValueByField("status");
4.     if(status.getLang().equals("es"))
5.     {
6.         this.collector.emit(new Values(status));
7.     }
8. }
```

Figura 4.22: Implementación del método *execute* del *bolt* de idioma.
Fuente: Elaboración Propia, (2016)

Aunque simple, éste operador filtra un gran número de estados, dado que según lo dicho anteriormente, la mayoría de los usuarios de *Twitter* no son hispano-hablantes.

Operador filtro de consultas

El segundo nivel de operadores consiste en un segundo filtro, en este caso, los filtros introducidos por el usuario para discriminar *tweets* según su contenido. Esto buscando centrar la atención del sistema en los términos importantes para el usuario. De esta forma la cantidad de datos que ingresa al sistema puede verse reducida aún más en función de qué términos se hayan sido especificados.

Adicionalmente a lo anterior, correspondiente a la HU-v05, se encuentra que la historia HU-c02 que guarda relación con ésta. Menciona la necesidad de incrementar los términos de búsqueda para enriquecerla y así incrementar la cantidad de *tweets* relacionados al evento. Para realizar esto se consideró una práctica del procesamiento de lenguaje natural como es la denominada *Query Expansion* (QE). Según lo descrito por Manning et al. (2008) son técnicas comunes al utilizar QE la búsqueda de sinónimos (uso de diccionarios privamente

establecidos), diccionarios basados en la minería de los elementos previamente hayados, creación de diccionarios basados en la co-ocurrencia de términos, es decir, términos que suelen venir juntos o un vocabulario mantenido por editores humanos. Para este trabajo sólo se consideran las dos primeras: Búsqueda por diccionario de sinónimos y una implementación que encuentra los términos más frecuentes dentro de los resultados de la búsqueda.

El diccionario de sinónimos es básicamente una bolsa de palabras asociadas a una semilla, es decir, dado un término de búsqueda, se agregan tantos términos nuevos a este filtro como sinónimos estén relacionados a al término en cuestión.

Para en el caso de la búsqueda de términos frecuentes, mencionada anteriormente, se sugirió integrar un proyecto *storm* ya desarrollado el cuál tiene por finalidad la búsqueda de los denominados *trending topics*, es decir, aquellos términos de los que se realizan más menciones en un determinado instante, pero aquella implementación sólo consideraba los denominados *hashtag*, un marcador de palabras concatenadas que inician por el caracter "#". Siendo ese el caso el uso de esta topología storm no es del todo útil. En su lugar se desarrolla un contador de frecuencias para palabras con un funcionamiento similar, dicha implementación se aprecia en el Algoritmo 4.4.

Algoritmo 4.4: Algoritmos de términos recurrentes.

Entrada: Estados $E = \{e_1, \dots, e_n\}$.

Salida: Terminos frecuentados $T = \{t_1, \dots, t_{10}\}$.

Lista de terminos: l .

Para Estado: e_i **Hacer:**

Dividir estado por palabra.

Eliminar *stopword* de las palabras.

Para Palabra: w_i en e_i **Hacer:**

Si w_i está en l_i **entonces:**

aumentar contador de w_i en l_i .

Sino:

agregar w_i a l_i con contador en 1.

Fin Si

Fin Para

Fin Para

Si l_i tiene menos de 10 elementos **entonces:**

Retornar l_i

Sino:

Retornar los 10 primeros elementos de l_i .

Fin Si

Dado que el operador puede estar replicado no se reciben los mismos *tweets* en todas las instancias de éste, por ello este proceso se realiza de manera única para cada instancia en función de los estados que hayan llegado a él. El Algoritmo 4.4 agrega a los términos de búsqueda de cada instancia las palabras más frecuentes y, siguiendo el ejemplo de *Twitter* con sus *trending topics* tiene un máximo de diez nuevas palabras.

```
1. @Override
2. public void execute(Tuple tuple) {
3.     Status status = (Status) tuple.getValueByField("status");
4.     CurrentQueryChecker cqc = new CurrentQueryChecker();
5.     /*Revisa la última query*/
6.     cqc.check();
7.     if(this.checkQueryMatch(queryExpander.expandQuery(cqc), status)){
8.         this.collector.emit(new Values(status));
9.     }
10. }
```

Figura 4.23: Implementación del método *execute* del *bolt* del filtro de consultas.

Fuente: Elaboración Propia, (2016)

La Figura 4.23 muestra la implementación del filtro de consultas. Hace uso de instancias de los objetos descritos en HU-v05 para encontrar la última consulta en el sistema y expande la consulta según ésta y los resultados obtenidos en los estados recibidos. Finalmente y si el estado contiene algunos los términos especificados, éste es emitido al siguiente nivel de operadores.

Operador normalizador de texto

El tercer problema es inherente a *Twitter*: En esta red social es común referenciar un estado a un determinado tema, he ahí el uso de los conocidos *Hashtag* que, como se mencionó en la sección 4.4.1 corresponden a palabras concatenadas antecedidas por el caracter #. Otro problema común corresponde a la mención de usuarios, ésta trata de una referencia al nombre de usuario dentro de la aplicación antecedida por el caracter "@" (usualmente utilizada para el envío de mensajes entre pares). Diversos autores, entre ellos, Lynn et al. (2015), Arshi Saloot et al. (2015) y Bonzanini (2015), han señalado que la existencia de estos elementos significan una disminución en la precisión de los elementos descritos en la sección 4.3.7. Dado lo anteriormente expuesto, el tercer operador corresponde a normalizador de texto, el cual reemplaza menciones a usuarios, *hashtags* y URLs, todas ellas de contenido variable, por palabras marcadores. El reemplazo a realizarse se muestra en la Tabla 4.2.

Tabla 4.2: Reemplazo de entidades en texto.
Fuente: Elaboración Propia, (2016)

Entidad	Marcador
@usuario	USUARIO
#hashtag	HASHTAG
http://var.foo/	URL

La implementación de éste operador se realizó utilizando expresiones regulares para detectar cuándo se está haciendo referencia a uno de los elementos anteriores y luego aplicar su reemplazo.

Operador geolocalizador

El cuarto y mayor problema presentado tiene relación, principalmente, con la historia HU-v01. Si bien se mencionó cómo se realiza la visualización, no se señaló cómo es que se obtienen tanto la coordenadas geográficas, latitud y longitud, para ubicar geográficamente un evento.

Ha sido señalado por Imran et al. (2014a) que menos del 1% de los *tweets* contienen datos en sus campos correspondientes a geolocalización. En un experimento (véase Apéndice A) realizado utilizando la herramienta *RapidMiner* se obtuvo una muestra de 67.789 *tweets*

directamente desde el *stream* sin utilizar filtros de búsqueda, de esos *tweets* 67.475 no contaban con los datos correspondientes a la ubicación geográfica, es decir, el 0.46% de los datos de aquella muestra cuentan con la información requerida, lo que hace creer que lo presentado por los autores, antes mencionados, está en lo correcto.

Siendo la geolocalización un elemento de suma importancia para el funcionamiento de la aplicación, es necesario construir un mecanismo alternativo capaz de asociar los eventos a lugares geográficos. Para llevar a cabo esta tarea, se propone explotar el contenido del *tweet* para buscar lugares geográficos explícitamente mencionados en el texto. Para ello se generó de manera manual un diccionario con todas las comunas del país y sus coordenadas geográficas, Carta-natal (2016) y se diseñó el Algoritmo 4.5. De esta manera existe una aproximación para detectar la ubicación a la que un *tweet* hace referencia.

Algoritmo 4.5: Algoritmos de ubicación geográfica.

Entrada: Lista de ciudades $C = \{c_1, \dots, c_n\}$.

Entrada: Tweet t .

Salida: Coordenadas geográficas $P = \{latitud, longitud\}$.

Si t está geolocalizado **entonces:**

Si Está dentro del territorio chileno **entonces:**

Retornar Coordenadas del t .

Sino:

Retornar Fuera de Chile.

Fin Si

Sino:

Si El texto de t contiene elementos presentes en C **entonces:**

Retornar Coordenadas de c_i .

Sino:

Retornar No geolocalizable.

Fin Si

Fin Si

Para detectar cuándo una ubicación está en Chile, se generó un cuadro en el mapa donde se delimita todo el territorio Chileno, incluyendo Isla de Pascua.

Haciendo uso del algoritmo desarrollado es posible aumentar la cantidad de elementos continuando siendo procesados por el sistema, en lugar de utilizar sólo el porcentaje de datos que contienen datos de la ubicación, pero se ha de recalcar que un dato cuya ubicación no pueda ser obtenida, no continuará al siguiente nivel de operadores de la topología. Su efectividad radica en la aparición del nombre de una localidad chilena en el texto.

Operador removedor de stopword

Existen palabras que, según lo descrito en Manning et al. (2008) y presentado por Susmel (2016), aportan poco o nada información al texto, estas palabras son denominadas *stopwords* y se componen de artículos, pronombres, preposiciones, etcétera. Éste operador hace uso de una lista de *stopwords*, las que son eliminadas del texto que se está procesando, para ello se hace uso del Algoritmo 4.6 presentado a continuación.

Algoritmo 4.6: Algoritmos de eliminación de *stopwords*.

Entrada: Lista de *stopwords* $S = \{s_1, \dots, s_n\}$.

Entrada: Texto T .

Salida: Texto T' .

$$T' = T$$

Para cada palabra de T , t_i **Hacer:**

Si t_i está contenida en S **entonces:**

$$T' = T' - t_i.$$

Fin Si

Fin Para

Retornar T'

Operador raíz de texto

Un clasificador no sabe reconocer que palabras, por ejemplo, en diferente tiempo verbal hacen referencia a lo mismo y las procesa como dos elementos independientes, para evitar aquello una técnica común en el procesamiento de lenguaje natural, más específicamente en la clasificación de texto, es llevar las palabras a una raíz común para ahorrar este problema al clasificador.

Este operador hace uso del algoritmo de Porter (1979), para extraer prefijos y sufijos de palabras y llevarlas a una raíz común, Ramírez (2012), son ejemplos de este proceso, denominada *stemming*, las palabras presentadas en la Tabla 4.3

Tabla 4.3: Ejemplo de *stemming* para la palabra 'presentar'.
Fuente: Elaboración Propia, (2016)

Palabra	Combinaciones de Sufijos
Presentarla	arla
Presentarlas	arlas
Presentarle	arle
Presentarles	arles
Presentarlo	arlo
Presentarlos	arlos
Presentarse	arse
Presentase	ase
Presentásemos	ásemos
Presente	e
Presentémonos	émonos

Operador etiquetador

El funcionamiento principal del sistema está en detectar necesidades expresadas en el texto. Para ello se construyó un clasificador bayesiano (cuyo detalle de construcción se presenta en las más adelante en esta sección). En primer lugar se recibe desde los operadores previos, un texto preparado para ser etiquetado, este texto es transformado en *tokens* (un vector de elementos donde cada elemento corresponde a una palabra) y posteriormente es entregado a Mallet, herramienta que hace uso del clasificador construido y, según el resultado de la evaluación de éste, le asigna la correspondiente etiqueta.

Al contar con este dato ya se está en condiciones de generar un nuevo marcador, pues se tienen todos los elementos necesarios en un documento de la colección marcadores presentados en la Figura 4.19, así entonces los datos recibidos más la etiqueta correspondiente a la clasificación son emitidas para ser recibidas por el operador de persistencia.

Operador persistencia

Habiendo pasado por todos los operadores descritos anteriormente es necesario comunicar los nuevos eventos detectados al visualizador para que los posicione en el mapa. Para ello se hace uso de la base de datos, como fue explicado en la sección 4.3.1. Este operador se encarga de conectarse a la base de datos y almacenar el nuevo marcador. Los datos recibidos desde la cadena de procesamiento se lleva a una instancia de objeto Java, llamado "Marker", el cual contiene los mismos elementos descritos para un documento de la colección "Markers", a un objeto JSON utilizando *Jackson* y finalmente, utilizando *Jongo*, lo transforma en BSON para almacenarlo en la base de datos en MongoDB.

Proceso de construcción del clasificador

Hasta ahora se han tocado, prácticamente, todos los temas que se relacionan con el funcionamiento del sistema de detección, desde donde se obtienen los datos, por que operadores pasa para ser procesado e incluso como se almacenan, pero no se ha especificado cómo se realiza la clasificación, es decir, cómo dado un texto de entrada se consigue discriminar en qué categoría encaja. Esta sección busca dar a conocer el proceso de construcción del clasificador haciendo uso de la metodología KDD.

El concepto que involucra la construcción de un clasificador es el de "aprendizaje supervisado", que fue mencionado en la sección 2.1.2, en este tipo de aprendizaje se requiere de un conjunto de datos de entrada, denominados conjunto de entrenamiento, que ha de pasar por el algoritmo, en este caso *Naïve Bayes*, que ha de conocer previamente, la salida esperada para cada elemento del conjunto. El resultado esperado es un clasificador capaz de predecir, en este caso, a qué categoría pertenece un texto sometido a su evaluación.

Según la metodología KDD existen subprocesos en la búsqueda de conocimiento en bases de datos, estos fueron descritos en la sección 1.5.1, para este caso particular se describe cómo fue realizado cada uno de estos subprocesos para la construcción del clasificador con el que cuenta el sistema.

El subproceso de selección de datos se llevó a cabo extrayendo un subconjunto del *dataset* mencionado en la sección 1.4.3. Éste conjunto, de exactamente 2234 *tweets* correspondientes al terremoto de Concepción el año 2010, todos ellos en español, pero no todos referencian al evento, pues éste coincidió con la realización de la LI versión del Festival Internacional de la Canción de Viña del Mar y muchos de estos *tweets* hacen referencian a este último. Los datos en este punto de proceso cuentan con los campos correspondientes a un *tweet* de la época, es decir: "ID_unit", "day", "date", "time_zone", "time", "tweet_it", "user_id", "name", "screen_name", "friends_count", "follower_count", "text" y "value". Todos ellos separados por coma (,).

En cuanto al subproceso de preprocesamiento de datos, el primer paso corresponde a la limpieza de los datos, en conjunto de datos que se está utilizando contenía elementos incompletos que no presentaban texto, estos fueron eliminados, pues no resultaban útiles sin este componente, quedando así un total de 2187 *tweets* con datos útiles.

El siguiente paso, correspondiente al subproceso de transformación de datos, del conjunto de datos útiles se extrajo el texto y se eliminaron todos los demás componentes. Llegados a este punto sólo se contaba con una lista de textos de *tweets* en español. Lo siguiente a realizar corresponde al proceso de etiquetado, para ello se leyó cada una de las entradas de texto y según su contenido se ubicó, manualmente, en alguna de las categorías descritas en la sección 4.3.6, además se asignó un identificador a cada texto, basado en su número, para ser

ingresados a la herramienta Mallet, encargada de la construcción del clasificador, así se obtuvo un archivo con los datos formateados según lo descrito en la sección 4.3.7, es decir, con los campos "Identificador", "Etiqueta", "Contenido". En este punto los datos fueron ingresados al sistema para la aplicación de los operadores descritos en la sección 4.4.2, en particular la eliminación de *stopwords*, normalización de texto y *stemming*.

El cuarto subproceso es automatizado por Mallet y corresponde al minado de datos en sí, para entregarle los datos a Mallet primero han de construirse como un objeto "*Instance*", lo cual se realiza entregándole cada uno de los elementos preparados en la sección anterior: el identificador, etiqueta y contenido que ya ha pasado por las operaciones que componen el subproceso de transformación. Se configuró Mallet para construir un clasificador utilizando un 90% del conjunto para entrenar y un 10% para realizar la evaluación. Como resultado de este proceso se obtiene un objeto *Classifier*, el cual puede ser serializado y almacenado como un archivo denominado, en este caso, "classifier.dene".

Finalmente el subproceso de evaluación también es llevado a cabo por la herramienta Mallet, que implementa un objeto denominado "*Trial*" el cual, utilizando un clasificador y un conjunto de datos de prueba. Como resultado de este subproceso se obtienen las métricas comunes de evaluación: *accuracy*, *recall* y *F-1 score*. La evaluación del clasificador construido se presenta en la sección 5.2 del Capítulo 5.

Topología del sistema

Habiendo definido los elementos de procesamiento, los operadores o *bolts*, se está en condición de definir la topología. La topología que utiliza el sistema, en términos generales de la aplicación está definida en la Figura 4.24.

La razón de este orden en la topología se debe a varias razones y se justifican a continuación:

- *Spout Twitter*: Es el eslabón principal de la cadena. Desde aquí se emiten los nuevos estados al sistema y todo el sistema depende de él.
- *Bolt Filtro de idioma*: Ocupa la primera posición de los operadores del sistema, dado que se espera que el *stream* reciba estados de todo el mundo y no sólo en español. Al estar este operador en primer lugar se asegura de reducir el flujo en gran medida, lo cual puede comprobarse por los resultados obtenidos en el Capítulo 5.
- *Bolt Filtro de consulta*: Habiendo filtrado sólo aquellos estados cuyo language sea el español es necesario filtrar aun más el *stream* valiéndose de las restricciones especificadas por el usuario. Así sólo los estados que contengan términos especificados por el usuario, o el sistema de expansión, continúan en el sistema.

- *Bolt* Normalizador de texto: Previo al detector de ubicación para evitar posibles confusiones que pueda acarrear la existencia de nombres de lugares en elementos como nombres de usuario, *hashtags* o enlaces.
- *Bolt* Detección de ubicación: Ocupa ésta posición, pues debe ir previo a la eliminación de *stopwords*, de lo contrario ubicaciones, como por ejemplo "los vilos", válida dentro de chile, es ignorada por el sistema.
- *Bolt* Eliminador de *stopword*: Se realiza previo al *Stemming* para reducir la carga computacional, pues el operador de *stemming* lleva a palabras raíz estos términos que no son necesarios.
- *Bolt Stemmer*: Es la única ubicación posible para este operador, pues el siguiente paso es etiquetar el estado.
- *Bolt* Etiquetador: Aplica el modelo al estado, el estado ha de tener su correspondiente etiqueta antes de ser almacenado.
- *Bolt* Persistencia: último eslabón de la cadena. Ingresar un nuevo documento a la colección de marcadores.




Figura 4.24: Topología general del sistema.
Fuente: Elaboración Propia, (2016)

Puede verse que corresponde a una topología lineal, cada operador estará replicado dependiendo de su carga y con un máximo definido por el administrador del sistema. Existe la posibilidad de hacer uso de algoritmos automáticos para ajustar el nivel de replicación, sin embargo está fuera de los alcances del proyecto.

CAPÍTULO 5. EVALUACIÓN DEL SISTEMA

Con el sistema construido resta someterlo a evaluaciones. En especial se evalúa el sistema de detección de necesidades, pues es el corazón del sistema y ha de operar con un flujo de datos constante.

5.1 CUMPLIMIENTO DE REQUERIMIENTOS

En cuanto a la construcción del *software*, se identificaron 12 historias de usuario y se especificaron cada uno de sus criterios de aceptación. Se pasa a detallar por cada historia si ésta fue cumplida o no.

- HU-c00: Mediante la construcción de un operador, *spout*, que haciendo uso del *stream* de datos proporcionado por *Twitter* recogiese los datos en tiempo real y la construcción de un clasificador de texto es que se completo esta historia.
- HU-c01: De igual manera que la historia anterior, haciendo uso de la información de *Twitter*, ésta historia se completó.
- HU-c02: Esta historia se completó mediante la construcción del operador filtro de consulta, donde se añadió la capacidad de realizar *query expansion*.
- HU-v03: Se implementó mediante el actualizador del modelo de clasificación, dejando al usuario la tarea de etiquetar los datos para formar el conjunto de entrenamiento.
- HU-c04: Se implementó mediante una base de datos no relacional en tres colecciones de datos: marcadores, *tweets* y consultas.
- HU-v00: Con la construcción de la aplicación visualizadora, la que permite el despliegue de una interfaz web al usuario esta historia se marcó como completada.
- HU-v01: Mediante el operador de ubicación ésta historia de usuario se completó.
- HU-v02: Se implementaron filtros haciendo uso de Javascript a la interfaz, permitiendo realizar veintiún formas de visualización diferentes.
- HU-v03: Al igual que la historia anterior, se utilizó Javascript, en específico AJAX, para que, mediante un servicio REST se pudiese actualizar los nuevos marcadores.

- HU-v04: Se utilizó una librería externa, *HighCharts*, para la implementación de una línea de tiempo con intervalo deslizante y, mediante un servicio REST, obtener los datos pertenecientes al intervalo seleccionado y cumplir así ésta historia de usuario.
- HU-v05: Se implementó junto con la historia de usuario HU-c02. El filtro de consultas permitía el paso de los *tweets* que tuviesen parte de su contenido alguno de los términos especificados por el usuario.
- HU-v06: Se diseñaron 7 iconos para corresponder a cada una de las categorías y completar esta historia, la descripción de estos es entregada por medio de la aplicación de visualización al usuario final.
- HU-v07: Mediante la construcción de tres servicios rest que cuenten la cantidad de eventos desde la última consulta se completó esta historia de usuario.
- HU-v08: Se permitió al usuario el parametrizar la configuración de la aplicación visualizadora, completando así esta historia de usuario.

5.2 EVALUACIÓN DEL CLASIFICADOR

En esta sección, el clasificador construido en la sección 4.4.2 fue sometido a evaluación, se presentan en la Figura 5.1 los resultados correspondientes a las métricas obtenidas usando Mallet.

Clase	Accuracy (%)	Recall (%)	F-1 Score
Agua	87,11	8,00	14,81
Electricidad		5,00	9,52
Alimento		0,00	0,00
Comunicación		15,79	26,86
Seguridad		36,00	52,83
Personas		65,58	77,09
Irrelevante		99,47	92,50

Figura 5.1: Métricas del clasificador.

Fuente: Elaboración Propia, (2016)

Los valores expuestos anteriormente son interpretados, respectivamente, como sigue a continuación.

- *Accuracy*: Este valor quiere decir qué con, aproximadamente, un 87% al decir que un elemento pertenece a una determinada clase esa predicción es correcta.

- *Recall*: Este valor quiere decir que para una clase en particular, es posible identificar es posible identificar en un determinado porcentaje p , correspondiente al valor presentado en la Figura 5.1, de los elementos pertenecientes a aquella clase.
- *F-1 Score*: Corresponde al *trade-off* entre *accuracy* y *recall*, al incrementar uno, el otro disminuye en un $F\%$ descrito por los valores en la Figura 5.1.

En particular este clasificador cuenta con alta precisión y bajo *recall*, eso significa que el es preciso para clasificar, pero es incapaz de clasificar algunos de los casos particulares de cada clase. Esto se debe al conjunto de entrenamiento utilizado, los datos no están balanceados para cada clase, es decir, la clase A, no tienen la misma cantidad de datos utilizados para entrenar B, esto repercute en que debido a las pocas instancias que tiene el algoritmo para aprender no es capaz de reconocer elementos de la clase con menos elementos. En particular el caso de la clase "Alimentos", los datos que se utilizaron son del periodo inmediato al evento, por ello no se encontraron demasiados elementos que hagan referencia a la falta de alimento en una población. Específicamente sólo se etiqueto un *tweet* presentado en la Tabla 5.1 dentro de la categoría alimento. Esto se debe al que el el conjunto de *tweets* utilizado corresponde a uno obtenido en el periodo inmediato del evento, probablemente si el conjunto contemplara *tweets* obtenidos un tiempo después de la ocurrencia de éste, la cantidad de elementos clasificados dentro de la categoría alimentos aumentaría.

Tabla 5.1: Estados dentro del conjunto de entrenamiento cuya categoría es alimento.
Fuente: Elaboracion Propia, (2016)

Categoría	Tweet
Alimento	"chilenos se vuelcan a supermercados y estaciones de servicio tras terremoto http://myloc.me/4giya "

5.3 TOPOLOGÍA Y REPLICACIÓN

En la sección 4.4.2 se explicitó cómo están dispuestos los operadores en la topología, pero se ha de recordar que el sistema está pensado para operar en casos de emergencia y ha de ser capaz de escalar de acuerdo a las necesidades de la situación.

Apache Storm es capaz de realizar lo anterior, pero se ha de especificar el máximo número de nodos que tiene cada nivel de operadores. La Figura 5.2 presenta la implementación de la topología inicial, mientras que la Figura 5.3 presenta gráficamente cómo se vería esta topología.

```

1. public static void main(String[] args) {
2.     TopologyBuilder builder = new TopologyBuilder();
3.
4.     builder.setSpout("TwitterSpout", new TwitterSpout(), 2);
5.
6.     builder.setBolt("LanguageFilter", new LanguageFilter(), 4).shuffleGrouping("TwitterSpout");
7.     builder.setBolt("QueryFilter", new QueryFilter(), 4).shuffleGrouping("LanguageFilter");
8.     builder.setBolt("TextNormalizer", new TextNormalizer(), 4).shuffleGrouping("QueryFilter");
9.     builder.setBolt("LocationRecognizer", new LocationRecognizer(),
10.    4).shuffleGrouping("TextNormalizer");
11.     builder.setBolt("StopwordRemover", new StopwordRemover(),
12.    2).shuffleGrouping("LocationRecognizer");
13.     builder.setBolt("TextStemmer", new TextStemmer(), 2).shuffleGrouping("StopwordRemover");
14.     builder.setBolt("Labeler", new Labeler(), 2).shuffleGrouping("TextStemmer");
15.     builder.setBolt("Persistence", new Persistence(), 1).shuffleGrouping("Labeler");
16.
17.     Config conf = new Config();
18.     conf.setDebug(false);
19.
20.     LocalCluster cluster = new LocalCluster();
21.     cluster.submitTopology("Deteccion-Necesidades", conf, builder.createTopology());
22. }

```

Figura 5.2: Implementación topología de detección de necesidades.

Fuente: Elaboración Propia, (2016)

La Figura 4.4.2 se hace uso de una instancia de *TopologyBuilder*, donde se especifican cada uno de los elementos de la topología. Para el caso de los *bolts* (líneas 6 a la 13), se hace uso del método *setBolt*, al que, además del nombre que tendrá dentro de la topología, se entrega como parámetro una instancia del operador y se especifica cuál será su nivel de replicación. Además se especifica el modo en el que se enviarán las tuplas para el procesamiento, en este caso, se hace uso de *shuffle grouping*, para entregarlas de forma *round-robin* y balancear la carga en cada instancia del operador.




Figura 5.3: Esquema de la topología en el caso de máxima actividad.
Fuente: Elaboración Propia, (2016)

Cada línea de este esquema presentado en la Figura 5.3 señala comunicación de izquierda a derecha. En el caso de que el sistema trabaje al máximo de su capacidad cada nodo envía, *round robin*, eventos al siguiente nivel.

Al ejecutar la topología antes descrita se detectó que el hecho de tener dos *spout* resultaba contraproducente, pues enviaba, en repetidas ocasiones, el mismo *tweet* al sistema, es decir, cuando el *spout* A enviaba el *tweet* t_0 , probablemente el *spout* B enviase el mismo *tweet* t_0 , es decir, el resto del sistema procesaba el trabajo dos veces. Para solucionar esto se decidió eliminar el segundo *spout* y limitarlo sólo a uno.

Habiendo realizado lo anterior, se utilizó el tiempo de ejecución obtenido para el procesamiento de 1000, 2000, 4000 y 8000 eventos por esta topología, correspondientes a *tweets* del terremoto de Concepción el año 2010 para seleccionar cuán numeroso debería ser un nivel de nodos. Sus resultados son expuestos en la tabla 5.2.

Tabla 5.2: Estadísticas de los operadores diversos eventos.
Fuente: Elaboración Propia, (2016)

Entradas (eventos)	Métricas	Operadores			
		Idioma	Normalizador	Ubicación	Stopword
1000	Procesados	1000	1000	1000	1000
	Emitidos	402 (40.20%)	1000 (100%)	623 (62.30%)	1000 (100%)
	Descartados	598 (59.80%)	0 (0%)	377 (37.70%)	0 (0%)
	Tiempo (ms)	0.77	36,45	2111.73	30.54
2000	Procesados	2000	2000	2000	2000
	Emitidos	807 (40.35%)	2000 (100%)	1058 (52.90%)	2000 (100%)
	Descartados	1193 (59.65%)	0 (0%)	942 (47.10%)	0 (0%)
	Tiempo (ms)	0.84	56.07	1314.53	45.23
4000	Procesados	4000	4000	4000	4000
	Emitidos	1673 (41.83%)	4000 (100%)	1985 (49.63%)	4000 (100%)
	Descartados	2327 (58.17%)	0 (0%)	2015 (50.37%)	0 (0%)
	Tiempo (ms)	2.08	49.09	2155.30	71.09
8000	Procesados	8000	8000	8000	8000
	Emitidos	3101 (38.76%)	8000 (100%)	4113 (51.41%)	8000 (100%)
	Descartados	4899 (61.24%)	0 (%)	3887 (48.59%)	0 (0%)
	Tiempo (ms)	3.37	59.53	4442.00	87.24

Con estos resultados se busca definir el numero de réplicas necesarios para cada operador a modo de reducir la latencia y mantener los datos fluyendo. por cada nivel de *bolts*, de los resultados presentados en la Tabla 5.2 podemos concluir lo siguiente:

Para el caso del operador filtro de idioma, para diferentes tamaños de conjuntos de estados, es emitido, aproximadamente, un 40.28% del flujo de información que llega a aquel operador. Tiene un tiempo de ejecución reducido en comparación a los demás operadores.

En operadores normalizadores de texto y eliminación de *stopwords* todo estado que llega es emitido.

El operador de ubicación admite, aproximadamente, un 54.06% de los *tweets* que llegan hasta el y presenta un elevado tiempo de ejecución.

Estos resultados muestran el comportamiento individual de cada uno de estos bolts, pero su operación no es de esta forma, por ello se preparó el mismo conjunto de pruebas de 1000, 2000, 4000 y 8000 datos aleatorios del conjunto de datos del terremoto de Concepción el año 2010 y se pasó al sistema para ver la cantidad de eventos emitidos en cada caso. Para el caso del operador de consulta se utilizaron los términos "terremoto", "concepción" y "Chile". Se restringió el paralelismo de la topología completa para realizar estas pruebas, es decir, cada operador tuvo, como máximo, una instancia trabajando durante todo el proceso.

Tabla 5.3: Prueba sistema completo utilizando 1000 eventos.
Fuente: Elaboración Propia, (2016)

Cantidad	1000	
Operador	Eventos recibidos	Eventos emitidos
Spout	1000	1000
Idioma	1000	402
Consulta	402	123
Normalizador	123	123
Ubicacion	123	0
Stopword	0	0
Stemmer	0	0
Etiquetador	0	0
Persistencia	0	0

Tabla 5.4: Prueba sistema completo utilizando 2000 eventos.
Fuente: Elaboración Propia, (2016)

Cantidad	2000	
Operador	Eventos recibidos	Eventos emitidos
Spout	2000	2000
Idioma	2000	807
Consulta	807	78
Normalizador	78	78
Ubicacion	78	0
Stopword	0	0
Stemmer	0	0
Etiquetador	0	0
Persistencia	0	0

Tabla 5.5: Prueba sistema completo utilizando 4000 eventos.
Fuente: Elaboración Propia, (2016)

Cantidad	4000	
Operador	Eventos recibidos	Eventos emitidos
Spout	4000	4000
Idioma	4000	1673
Consulta	1673	39
Normalizador	39	39
Ubicacion	39	0
Stopword	0	0
Stemmer	0	0
Etiquetador	0	0
Persistencia	0	0

Tabla 5.6: Prueba sistema completo utilizando 8000 eventos.
Fuente: Elaboración Propia, (2016)

Cantidad	8000	
Operador	Eventos recibidos	Eventos emitidos
Spout	8000	8000
Idioma	8000	3101
Consulta	3101	151
Normalizador	151	151
Ubicacion	151	0
Stopword	0	0
Stemmer	0	0
Etiquetador	0	0
Persistencia	0	0

Las Tablas 5.3, 5.4, 5.5 y 5.6 muestran respectivamente los resultados para los datos antes mencionados. Pueden ser leídas secuencialmente, es decir, presenta los estados que pasan por un operador y son entregados al siguiente, estos resultados muestran la dificultad que tiene un *tweet* para completar el proceso, para confirmar que el sistema funcionase correctamente se incrementó la cantidad de datos, llegando a utilizar 30000 *tweets* para evaluarlo. Los resultados se presentan en la Tabla 5.7

Tabla 5.7: Prueba sistema utilizando 30000 eventos.
Fuente: Elaboración Propia, (2016)

Cantidad	30000	
Operador	Eventos recibidos	Eventos emitidos
Spout	30000	30000
Idioma	30000	5372
Consulta	5372	883
Normalizador	883	883
Ubicacion	883	0
Stopword	0	0
Stemmer	0	0
Etiquetador	0	0
Persistencia	0	0

Ninguno de los datos contenía información sobre la ubicación, por ello el operador encargado debe inferirla con respecto al texto, pero casos como por ejemplo el mostrado en la Tabla 5.8 muestran que no se estaba realizando este proceso correctamente.

Tabla 5.8: Resultado esperado del operador de ubicación.
Fuente: Elaboración Propia, (2016)

Eventos	Resultado esperado	Resultado obtenido
@tvn_mauricio x fin internet desde el movil, ciudad satelite maipu, sin luz ni agua desde el terremoto casi 30 hrs	Emitir(-33.51667, -70.76667)	No emitido

Dados los resultados de presumió un error en la implementación, por lo que se revisó el código *bolt* para encontrar el error.

Habiéndolo corregido se volvió a comprobar el comportamiento del sistema con el conjunto de 30000 *tweets*. De esta comprobación se obtuvieron los resultados presentes en la Tabla 5.9. Estos muestran que habiéndose producido el proceso de identificación, el último operador con las características de filtro, todos los estados pasaron a ser etiquetados y almacenados correctamente con la categorización realizada al ser evaluadas por el clasificador.

Es importante volver a hacer hincapié en que si bien, estos u otros resultados se ven influenciados por los términos que compongan la consulta activa en un determinado momento, también la afectará el contexto de los *tweets* recibidos hasta ese instante, pues con ellos se forma el conjunto de términos más usados, utilizado al expandir la consulta en este mismo operador.

Tabla 5.9: Nueva prueba al sistema con 30000 eventos.
Fuente: Elaboración Propia, (2016)

Cantidad	30000	
Operador	Eventos recibidos	Eventos emitidos
Spout	30000	30000
Idioma	30000	5372
Consulta	5372	883
Normalizador	883	883
Ubicacion	883	743
Stopword	743	743
Stemmer	743	743
Etiquetador	743	743
Persistencia	743	743

Estos resultados distan de los realizados para los operadores individuales y muestran que el flujo de información en el sistema haciendo uso de datos reales. Teniendo en cuenta estos resultados se modifica la topología inicial presentada en la figura 5.3 y pasa a utilizarse la presentada en la Tabla 5.11, sus valores se basan en el porcentaje de datos capaces de pasar el operador, siendo estos representados en la Tabla 5.10.

Tabla 5.10: Nivel general de replicación de la topología.
Fuente: Elaboración Propia, (2016)

Operador	Nivel de replicación
Spout	1
Idioma	N
Consulta	$C = \lceil 18\% \cdot N \rceil$
Normalizador	$\lceil 16\% \cdot C \rceil$
Ubicación	$U = \lceil 16\% \cdot C \rceil$
Stopword	$S = \lceil 84.14\% \cdot U \rceil$
Stemmer	S
Etiquetador	S
Persistencia	S

Donde N es un valor arbitrario determinado por el desarrollador. Para determinar un nivel de replicación para el sistema se determinó $N = 10$, así el sistema se entrega como el siguiente nivel de replicación máximo en sus operadores:

Tabla 5.11: Nivel máximo de replicación de la topología.

Fuente: Elaboración Propia, (2016)

Operador	Nivel de replicación
Spout	1
Idioma	10
Consulta	2
Normalizador	2
Ubicación	2
Stopword	1
Stemmer	1
Etiquetador	1
Persistencia	1

5.4 FUNCIONAMIENTO EN ALTO TRÁFICO

La siguiente gráfica presentada en la Figura 5.4 presenta el flujo de mensajes de *Twitter* entre las fechas 16 de febrero y 2 de marzo del año 2010 perteneciente al conjunto de datos utilizado, en ella se aprecia que se produjo un *peak* de *tweets* al momento de producirse el evento terremoto.




Figura 5.4: Distribución de estados presente en el conjunto de datos utilizado para evaluar.

Fuente: Elaboración Propia, (2016)

Este *peak* en la generación de datos no se ve reflejado como un aumento en la

cantidad de datos que llegan al *spout*, pues el la cantidad de mensajes por segundo ingresados por Twitter4J al sistema es constante mientras esté bajo la cuota límite de *Twitter*. En el sistema este incremento efecto se vería reflejado, probablemente, en un aumento de los *tweets* que aprueben el filtro de consultas si se están utilizando términos relacionados a este evento.

Teniendo en consideración lo anterior en cuanto a la cantidad de mensajes, se realizó una recopilación de eventos por un periodo de una hora del *stream* actual de eventos para obtener un total de 150.800 *tweets*. El gráfico presentado en la Figura 5.5 presenta la cantidad eventos acumulados en función del tiempo cuya pendiente indica que se reciben 42 eventos por segundo en promedio.

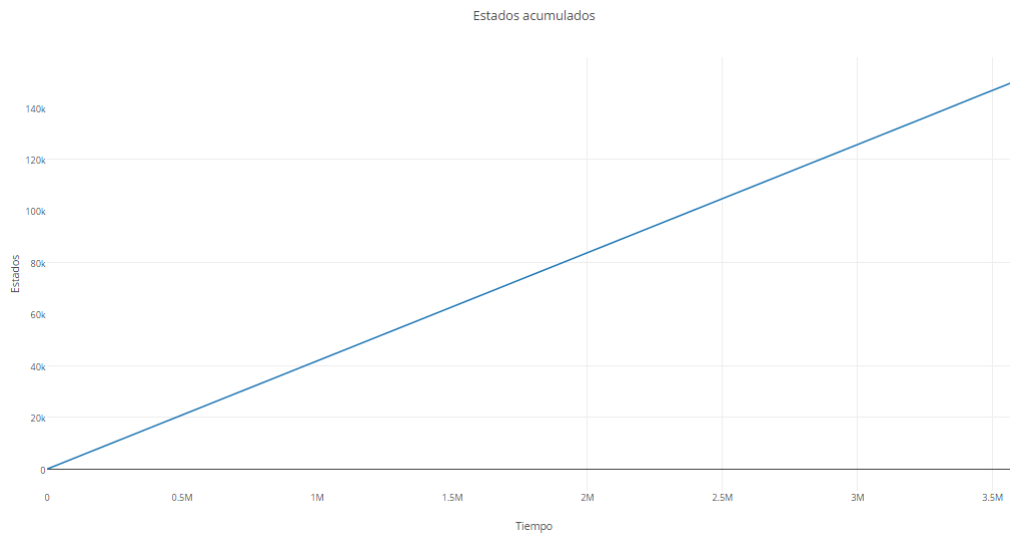


Figura 5.5: Recopilación de datos desde el *stream*.
Fuente: Elaboración Propia, (2016)

Haciendo uso de estos resultados se simuló la llegada de los eventos contenidos dentro de los datos de prueba sobre el sistema. Los resultados de esta simulación del comportamiento de la aplicación al operar como si fuese un evento real se muestran a continuación. La máquina para realizar estas pruebas fue la descrita en la sección 1.5.2 y se utilizó la herramienta YourKit. Se utilizaron 100.000 *tweets* del terremoto para realizar esta simulación y no se limitó la cantidad de eventos por segundo para probar el comportamiento del sistema con una carga de trabajo mayor a la habitual.




Figura 5.6: Uso de CPU durante la simulación.
Fuente: Elaboración Propia, (2016)

La gráfica presentada en la Figura 5.6 muestra el uso de la CPU del proceso *DeNe-Core* durante la simulación realizada, se ve gran variación del uso de CPU al comienzo de la operación, esto se debe al uso de un segundo *spout* encargado de emitir los *tweets* almacenados en un archivo del tipo JSON correspondientes al evento del año 2010, esto se aprecia en la Figura 5.7 que muestra la cantidad de archivos abiertos en el tiempo. Posterior a la carga de los datos al sistema, sin considerar el primer segmento, el uso de CPU se mantiene constante al rededor del 49% y permanece cercano a ese valor hasta que terminan de procesarse todos los *tweets*, aproximadamente, a 10 minutos desde el inicio de la prueba. Teniendo en consideración que se entregaron 100.000 *tweets* se procesan alrededor de 166 por minuto en esta prueba, eso es aproximadamente un 400% más de lo que es posible recoger desde el *stream* de *Twitter*, por lo que se espera que en condiciones normales de operación, y dada la limitante del tiempo real, el uso del CPU sea menor al presentado en esta prueba. Siempre teniendo en cuenta que la cantidad de mensajes que alcanzan la mayor parte del sistema están dados por qué halla especificado el usuario en sus términos de búsqueda. Para éste caso, se utilizaron los mismos términos especificados anteriormente: "terremoto", "Chile" y "Concepción."

A pesar de que esta es una prueba a pequeña escala, ya ha sido validado por otros sistemas la capacidad de escalar de los sistemas de procesamiento como *Storm*, ejemplo de ello son los trabajos realizados por Hidalgo et al. (2016), sca, Mishra (2015), entre otros.




Figura 5.7: Archivos abiertos durante la simulación.
Fuente: Elaboración Propia, (2016)

CAPÍTULO 6. CONCLUSIONES

Twitter al entregar a los desarrolladores un punto de acceso a la información que está fluyendo por la aplicación en tiempo real entrega una potente herramienta para la búsqueda de información, pues sus datos pueden ser objeto de análisis en diferentes áreas, por ejemplo, búsqueda de tendencias, política, eventos, etcétera. Lo que hace a *Twitter* tan especial es que cualquiera puede acceder a el, no en vano cuenta con millones de usuarios en todo el mundo y mediante su API posibilita obtener información generada por sus usuarios.

En emergencias es importante una rápida de decisiones, para así reducir el número de víctimas y distribuir de mejor manera los recursos disponibles; la información de redes sociales como *Twitter* puede ser de mucha ayuda para esto. Teniendo esto en consideración, se propuso una herramienta de apoyo a la gestión de desastres capaz de identificar y posicionar geoespacialmente la información expresada por los usuarios. Esta herramienta en particular identifica y clasifica necesidades expresadas en texto, de manera de poder priorizar la ayuda a aquellas zonas que presenten necesidades de mayor relevancia. Para ello se utilizaron técnicas de aprendizaje de máquina, en este caso, minería de textos. Ésta se diferencia de la minería tradicional dado que su fuente de información está en documentos y no en bases de datos.

Para el caso de *Twitter*, presenta un desafío pues su información, el texto del *tweet* en sí, no está estructurada, éste texto puede tener cualquier formato dentro de sus 140 caracteres. Para solucionar el inconveniente antes planteado y se utilizó la metodología KDD, que mediante sus cinco etapas permitió la construcción de un clasificador de texto utilizando el algoritmo de *Naïve Bayes*, con el cual es posible etiquetar nuevos datos para la detección de necesidades. Si bien, como se mencionó en la sección 5.2, el clasificador puede no ser el mejor, de hecho, presenta gran precisión, pero no es exhaustivo al momento de clasificar (bajo *recall*). La necesidad de tener un cuerpo de entrenamiento con gran cantidad de instancias fue un problema, pues el tiempo utilizado para etiquetar datos fue muy grande, para el caso del cuerpo utilizado de aproximadamente 2000 instancias se tardó dos horas continuas, para no retrasar el desarrollo se optó por no etiquetar nuevos datos para incrementar el tamaño del conjunto de entrenamiento y en su lugar, para solventar esta debilidad del sistema, se construyó un módulo que permitiese la actualización del clasificador.

El sistema de detección de necesidades consistió en dos aplicaciones, comunicadas por medio de la base de datos, así es posible manejar grandes cantidades de datos sin que el sistema colapse la memoria del equipo.

Sobre los objetivos específicos podemos señalar, respectivamente, lo siguiente con respecto a su completitud:

- Se implementó un *spout* capaz de obtener el *stream* de *Twitter*, para seleccionar aquellas

que hicieran referencia al territorio nacional se utilizó un segundo operador, el detector de ubicación.

- Se inició con el trabajo realizado por Olteanu et al. (2015), pero finalmente y avalado por el equipo de trabajo del proyecto FONDEF IDeA, se decidió utilizar una modificación de la categorización realizada por Hidalgo & Rosas (2014).
- Se construyó un cuerpo de entrenamiento, con el cual se diseñó un clasificador bayesiano haciendo uso de la herramienta Mallet.
- Mediante *Apache Storm* se definieron 8 elementos, además del *spout* para obtener los datos, con los cuales se dió soporte al sistema de detección de necesidades con capacidad de procesar grandes cantidades de datos.
- La escalabilidad está dada en primer lugar, y principalmente, por el uso de *Apache Storm*, pues la aplicación de detección es aquella que realiza todo el procesamiento del sistema, en tanto la aplicación visualizadora se vale de los tiempos de respuesta de la base de datos y, precisamente, en segundo lugar la rapidez en las respuestas a las consultas realizadas a la base de datos de MongoDB permiten que no se produzcan respuestas lentas al manejar un gran volumen de datos.
- Se simuló una condición en tiempo real de la aplicación haciendo uso de los datos recopilados en el terremoto de Concepción del año 2010 presentando en la sección 5.4 los resultado de ésta simulación. En pruebas realizadas no se vio influencia negativa dada la cuota máxima de accesos impuesta por *Twitter*, pero es un ítem que se ha de tener en cuenta al desplegar la aplicación para funcionar en modo producción, pues las esperas pueden significar datos perdidos.

Finalmente podemos señalar que, por medio de la concreción de los objetivos específicos señalados el sistema de detección de necesidades está completo y el objetivo general: "Construir un sistema escalable para la detección de necesidades de la población en tiempo real para escenarios de desastre natural haciendo uso de Twitter." se completó, presentando este sistema listo recolectar los datos desde *Twitter* y detectar los eventos categorizados como necesidades que allí aparezcan.

Habiendo concluido el desarrollo de la aplicación queda como trabajo futuro fundamentalmente dos puntos: Por un lado, la construcción de un conjunto de datos de entrenamiento más grande y cuyos elementos por clases estén balanceados como señala la teoría para permitir generar un mejor modelo de clasificación. Por otro la implementación de una API que dinámicamente encuentre los sinónimos de los términos de búsqueda para expandir de mejor

manera las consultas, en lugar de hacer uso de un diccionario de sinónimos estáticos con sólo ciertos términos.

Es importante señalar que aunque se utilizó para el desarrollo de éste trabajo un conjunto de datos correspondientes al terremoto de febrero del año 2010, el sistema no sólo sería capaz de detectar necesidades en estas circunstancias, es de propósito general, pero limitado por el clasificador que puede, como se mencionó, ser mejorado.

GLOSARIO

- **API:** acrónimo inglés para Application Programming Interface o Interfaz de programación de aplicaciones.
- **BSON:** es un formato de intercambio de datos usado principalmente para su almacenamiento y transferencia en la base de datos MongoDB. Es una representación binaria de estructuras de datos y mapas. El nombre BSON está basado en el término JSON y significa *Binary JSON* (JSON Binario).
- **Computación distribuida:** computación haciendo uso de distintos nodos para el procesamiento en lugar de la programación clásica en un único nodo.
- **Framework:** estructura que sirve de base para la organización y desarrollo del software. Puede proveer de soporte a programas y bibliotecas entre otros.
- **Hashtag:** secuencia de palabras concatenadas antecedidas por un gato (#), actúa como etiqueta.
- **Hot-spot** o cuello de botella: se refiere a nodos donde se producen cuellos de botella producto de que recibe información de muchos otros nodos y donde sólo este puede procesar la información.
- **JSON:** acrónimo de *JavaScript Object Notation*, es un formato de texto ligero para el intercambio de datos.
- **JVM:** una máquina virtual Java (JVM), es una máquina virtual de proceso nativo, es decir, ejecutable en una plataforma específica, capaz de interpretar y ejecutar instrucciones expresadas en un código binario especial el cual es generado por el compilador del lenguaje Java.
- **REST:** arquitectura de software presentada por Roy Fielding, para más información refiérase a su tesis doctoral. Fielding (2000).
- **Spike:** actividades de investigación, exploración y prototipado en metodologías ágiles.
- **Stream:** se refiere al flujo de información, en este contexto, al flujo de mensajes que se están produciendo en cada momento.
- **Trending Topic:** palabras o frases más repetidas en un momento en concreto.
- **Tradeoff:** anglicismo. se refiere a que debe sacrificarse algo para mejorar en otro.
- **Tweet:** los mensajes de *Twitter* son denominados como *tweets*. Tienen una longitud máxima de 140 caracteres.

- *Twitter*: servicio de microblogging. Permite enviar mensajes de texto de corta longitud.
- URL: secuencia de caracteres que siguen un formato estándar que asigna recursos en una red.
- *Performance*: anglicismo. Se refiere al rendimiento.
- *Stopwords*: anglicismo. Se traduce como Palabra vacía. Consiste en palabras sin significados como artículos, pronombres, preposiciones, etc. Suelen filtrarse para realizar procesamiento de lenguaje natural.

REFERENCIAS BIBLIOGRÁFICAS

(????).

Akidau, T., Balikov, A., Bekiroğlu, K., Chernyak, S., Haberman, J., Lax, R., McVeety, S., Mills, D., Nordstrom, P., & Whittle, S. (2013). Millwheel: Fault-tolerant stream processing at internet scale. *Proc. VLDB Endow.*, 6(11), 1033–1044.

URL <http://dx.doi.org/10.14778/2536222.2536229>

Apache (2015). Cassandra. Accedido el: 18/07/2016.

URL <http://cassandra.apache.org/>

Apache (2016a). Apache spark™ is a fast and general engine for large-scale data processing. Accedido el: 18/07/2016.

URL <http://spark.apache.org/>

Apache (2016b). Apache storm. Accedido: 18/07/2016.

URL <http://storm.apache.org/>

Arshi Saloot, M., Idris, N., Shuib, L., Gopal Raj, R., & Aw, A. (2015). Toward tweets normalization using maximum entropy. In *Proceedings of the Workshop on Noisy User-generated Text*, (pp. 19–27). Beijing, China: Association for Computational Linguistics.

URL <http://www.aclweb.org/anthology/W15-4303>

Bonzanini, M. (2015). Mining twitter data with python (part 2: Text pre-processing).

URL <https://marcobonzanini.com/2015/03/09/mining-twitter-data-with-python-part-2/>

Carta-natal (2016). Ciudades de chile. Accedido: 09/05/2016.

URL <https://carta-natal.es/ciudades/Chile/>

Codd, E. F. (1970). A relational model of data for large shared data banks. *Commun. ACM*, 13(6), 377–387.

URL <http://doi.acm.org/10.1145/362384.362685>

Condie, T., Conway, N., Alvaro, P., Hellerstein, J. M., Elmeleegy, K., & Sears, R. (2010). Mapreduce online. In *Proceedings of the 7th USENIX Conference on Networked Systems Design and Implementation*, NSDI'10, (pp. 21–21). Berkeley, CA, USA: USENIX Association.

URL <http://dl.acm.org/citation.cfm?id=1855711.1855732>

Dean, J., & Ghemawat, S. (2008). Mapreduce: Simplified data processing on large clusters. *Commun. ACM*, 51(1), 107–113.

URL <http://doi.acm.org/10.1145/1327452.1327492>

Dev.twitter.com (2016). Developer agreement and policy - twitter developers. Accedido: 05/07/2016.

URL <https://dev.twitter.com/overview/terms/agreement-and-policy>

eMarketer (2015). Latin america to register highest twitter user growth worldwide in 2015. Accedido: 07/07/2016.

URL <http://www.emarketer.com/Article/Latin-America-Register-Highest-Twitter-User-Growth-Worldwide-1012498>

Fayyad, U. M., & Uthurusamy, R. (Eds.) (1995). *Proceedings of the First International Conference on Knowledge Discovery and Data Mining (KDD-95), Montreal, Canada, August 20-21, 1995*. AAAI Press.

URL <http://www.aaai.org/Library/KDD/kdd95contents.php>

Fernández, I. (2011). Data mining: torturando a los datos hasta que confiesen. Accedido: 18/07/2016.

URL <http://textmining.galeon.com/>

- Fielding, R. T. (2000). *Architectural Styles and the Design of Network-based Software Architectures*. Ph.D. thesis. AAI9980887.
- Gautreau, G. (2010). jqrangeslider.
URL <http://ghusse.github.io/jQRangeSlider/index.html>
- Gonzales, P., & Wladdimiro, D. (2014). Online data processing on s4 engine: A study case on natural disasters. *IV Workshop de Sistemas Distribuidos y Paralelismo*, 4.
- Gulisano, V., Jimenez-Peris, R., Patino-Martinez, M., Soriente, C., & Valduriez, P. (2012). Streamcloud: An elastic and scalable data streaming system. *IEEE Trans. Parallel Distrib. Syst.*, 23(12), 2351–2365.
URL <http://dx.doi.org/10.1109/TPDS.2012.24>
- Hall, M., Frank, E., Holmes, G., Pfahringer, B., Reutemann, P., & Witten, I. H. (2009). The weka data mining software: An update. *SIGKDD Explor. Newsl.*, 11(1), 10–18.
URL <http://doi.acm.org/10.1145/1656274.1656278>
- Hidalgo, N., & Rosas, E. (2014). Despliegue Ágil de aplicaciones de apoyo a la gestión de desastres de origen natural y caso de estudio en sismología.
- Hidalgo, N., Wladdimiro, D., & Rosas, E. (2016). Self-adaptive processing graph with operator fission for elastic stream processing. *Journal of Systems and Software*, (pp. –).
URL <http://www.sciencedirect.com/science/article/pii/S0164121216300796>
- Hønsi, T., & Hjetland, G. (2006). Column - highcharts. Accedido: 15/06/2016.
URL <http://www.highcharts.com/stock/demo/column>
- Hunt, P., Konar, M., Junqueira, F. P., & Reed, B. (2010). Zookeeper: Wait-free coordination for internet-scale systems. In *Proceedings of the 2010 USENIX Conference on USENIX Annual Technical Conference*, USENIXATC'10, (pp. 11–11). Berkeley, CA, USA: USENIX Association.
URL <http://dl.acm.org/citation.cfm?id=1855840.1855851>
- Imran, M., Castillo, C., Diaz, F., & Vieweg, S. (2014a). Processing social media messages in mass emergency: A survey. *CoRR*, abs/1407.7071.
URL <http://arxiv.org/abs/1407.7071>
- Imran, M., Castillo, C., Lucas, J., Meier, P., & Vieweg, S. (2014b). Aidr: Artificial intelligence for disaster response. In *Proceedings of the 23rd International Conference on World Wide Web, WWW '14 Companion*, (pp. 159–162). New York, NY, USA: ACM.
URL <http://doi.acm.org/10.1145/2567948.2577034>
- Inc, G. (2014). Marker clusterer – a google maps javascript api utility library. Accedido: 01/06/2016.
URL <https://github.com/googlemaps/js-marker-clusterer>
- Iribarra, F. (2015). Descubrimiento del conocimiento (kdd) : “el proceso de minería”. Accedido: 01/05/2016.
URL <http://mineriadatos1.blogspot.cl/2013/06/descubrimiento-del-conocimiento-kdd-el.html>
- Jones, M. T. (2013). Procese big data en tiempo real con twitter storm. Accedido: 15/07/2016.
URL <https://www.ibm.com/developerworks/ssa/library/os-twitterstorm/>
- Lynn, T., Scannell, K., & Maguire, E. (2015). Minority language twitter: Part-of-speech tagging and analysis of irish tweets. In *Proceedings of the Workshop on Noisy User-generated Text*, (pp. 1–8). Beijing, China: Association for Computational Linguistics.
URL <http://www.aclweb.org/anthology/W15-4301>
- Macool (2013). Mysql vs postgresql vs mongodb (velocidad). Accedido: 28/05/2016.
URL <http://macool.me/mysql-vs-postgresql-vs-mongodb-velocidad/04>

- Maldonado, L. (2012). *Análisis de sentimiento en el sistema de red social Twitter*. Master's thesis, Universidad de Santiago de Chile, Av. Libertador Bernardo O'Higgins 3363, Santiago, Región Metropolitana. Memoria de pregrado.
- Manning, C. D., Raghavan, P., & Schütze, H. (2008). *Introduction to Information Retrieval*. New York, NY, USA: Cambridge University Press.
- McCallum, A. K. (2002). Mallet: A machine learning for language toolkit. [Http://mallet.cs.umass.edu](http://mallet.cs.umass.edu).
- Mierswa, I. (2016). Predictive analytics, reimagined. Accedido el: 18/07/2016.
URL <http://rapidminer.com/>
- Mishra, K. (2015). How spotify scales apache storm. Accedido el: 18/07/2016.
URL <https://labs.spotify.com/2015/01/05/how-spotify-scales-apache-storm/>
- Molina, L. (2002). Data mining: torturando a los datos hasta que confiesen. Accedido: 18/07/2016.
URL <http://www.uoc.edu/web/esp/art/uoc/molina1102/molina1102.html>
- MongoDB (2016). MongoDB for giant ideas. Accedido el: 18/07/2016.
URL <https://www.mongodb.com/>
- Nakatani, S. (2010). Language detection library for java. Accedido: 05/07/2016.
URL <https://github.com/shuyo/language-detection>
- Neumeyer, L., Robbins, B., Nair, A., & Kesari, A. (2010). S4: Distributed stream computing platform. In *Proceedings of the 2010 IEEE International Conference on Data Mining Workshops, ICDMW '10*, (pp. 170–177). Washington, DC, USA: IEEE Computer Society.
URL <http://dx.doi.org/10.1109/ICDMW.2010.172>
- Nguyen, D. T., & Jung, J. J. (2015). Real-time event detection on social data stream. *MONET*, 20(4), 475–486.
URL <http://dx.doi.org/10.1007/s11036-014-0557-0>
- Olteanu, A., Vieweg, S., & Castillo, C. (2015). What to expect when the unexpected happens: Social media communications across crises. In *Proceedings of the 18th ACM Conference on Computer Supported Cooperative Work & Social Computing, CSCW 2015, Vancouver, BC, Canada, March 14 - 18, 2015*, (pp. 994–1009).
URL <http://doi.acm.org/10.1145/2675133.2675242>
- Patrick Meier, J. K., Andrew Schroeder, & Lucas, J. (2016). Humanitarian uav network. Accedido el: 18/07/2016.
URL <http://uaviators.org/>
- Patrick Meier, J. L., & Leson, H. (2014). Micromappers digital disaster response. with a single click! Accedido el: 18/07/2016.
URL <http://micromappers.org/>
- Porter, M. (1979). The porter stemming algorithm. Accedido: 01/06/2016.
URL <https://tartarus.org/martin/PorterStemmer/>
- Purriños, A. (2014). MongoDB, ¿son las bases de datos no relacionales el futuro? Accedido el: 18/07/2016.
URL <http://www.revistacloudcomputing.com/2014/06/mongodb-son-las-bases-de-datos-no-relacional>
- Qian, Z., He, Y., Su, C., Wu, Z., Zhu, H., Zhang, T., Zhou, L., Yu, Y., & Zhang, Z. (2013). Timestream: Reliable stream computation in the cloud. In *Proceedings of the 8th ACM European Conference on Computer Systems, EuroSys '13*, (pp. 1–14). New York, NY, USA: ACM.
URL <http://doi.acm.org/10.1145/2465351.2465353>

- Ramos, J. A. (2015). Introducción a apache storm. Accedido: 15/04/2016.
URL <https://www.adictosaltrabajo.com/tutoriales/introduccion-storm/>
- Ramírez, K. (2012). Stemming – lematización. UCR – ECCI CI-2414 Recuperación de Información.
- Raschkowski, W. (2016). How to interpret f-measure values? Accedido: 15/07/2016.
URL <http://stats.stackexchange.com/questions/49226/how-to-interpret-f-measure-values>
- Russell, S. (2003). *Artificial intelligence : a modern approach*. Upper Saddle River, N.J: Prentice Hall/Pearson Education.
- Sanfilippo, S. (2015). redis. Accedido el: 18/07/2016.
URL <http://redis.io/>
- Satzger, B., Hummer, W., Leitner, P., & Dustdar, S. (2011). Esc: Towards an elastic stream computing platform for the cloud. In *Proceedings of the 2011 IEEE 4th International Conference on Cloud Computing, CLOUD '11*, (pp. 348–355). Washington, DC, USA: IEEE Computer Society.
URL <http://dx.doi.org/10.1109/CLOUD.2011.27>
- Smith, C. (2016). By the numbers: 170+ amazing twitter statistics. Accedido: 07/07/2016.
URL <http://bit.ly/1bSfjNi>
- SQLStream (2015). Stream processing explained. Accedido: 18/07/2016.
URL <http://www.sqlstream.com/stream-processing/>
- Statista (2016). Number of monthly active twitter users worldwide from 1st quarter 2010 to 1st quarter 2016 (in millions). Accedido: 07/07/2016.
URL <http://www.statista.com/statistics/282087/number-of-monthly-active-twitter-users/>
- Steven Bird, E. K., & Loper, E. (2009). *Natural Language Processing with Python: Analyzing Text with the Natural Language Toolkit*. Beijing: O'Reilly.
URL <http://www.nltk.org/book>
- Susmel, A. (2016). Machine learning: Working with stop words, stemming, and spam. Accedido el: 18/07/2016.
URL <https://www.codeschool.com/blog/2016/03/25/machine-learning-working-with-stop-words-stemming>
- Tirados, M. (2014). Apache spark, la nueva estrella de big data. Accedido el: 18/07/2016.
URL <http://www.bigdatahispano.org/noticias/apache-spark-la-nueva-estrella-de-big-data/>
- Tobin, J. (2016). Myth busting: MongoDB scalability (it scales!). Accedido: 04/05/2016.
URL <https://www.percona.com/blog/2016/02/19/myth-busting-mongodb-scalability/>
- Valer, S. (2011). *EVALUACIÓN DE TÉCNICAS Y SISTEMAS DE PROCESAMIENTO DE DATA STREAMS*. Master's thesis, Universidad de Zaragoza, Calle de Pedro Cerbuna, 12, 50009 Zaragoza, España. Master Thesis Computer Science.
- Verma, A., Cho, B., Zea, N., Gupta, I., & Campbell, R. H. (2013). Breaking the mapreduce stage barrier. *Cluster Computing*, 16(1), 191–206.
URL <http://dx.doi.org/10.1007/s10586-011-0182-7>
- Wells, D. (2013). Extreme programming: A gentle introduction. Accedido: 01/07/2016.
URL <http://www.extremeprogramming.org/>
- Weng, J., & Lee, B. (2011). Event detection in twitter. In *Proceedings of the Fifth International Conference on Weblogs and Social Media, Barcelona, Catalonia, Spain, July 17-21, 2011*.
URL <http://www.aaai.org/ocs/index.php/ICWSM/ICWSM11/paper/view/2767>

Xu, J., Chen, Z., Tang, J., & Su, S. (2014). T-storm: Traffic-aware online scheduling in storm. In *Proceedings of the 2014 IEEE 34th International Conference on Distributed Computing Systems*, ICDCS '14, (pp. 535–544). Washington, DC, USA: IEEE Computer Society.
URL <http://dx.doi.org/10.1109/ICDCS.2014.61>

APÉNDICE A. RECOLECCIÓN DE *TWEETS* CON RAPIDMINER

La recolección de *tweets* para comprobar el dato teórico correspondiente a la existencia de menos de un 1% de los *tweets* de *Twitter* contienen datos sobre su ubicación geográfica, se llevó a cabo haciendo uso de RapidMiner. Ésta herramienta permite recolectar *tweets* desde la API pública de *Twitter* y generar estadísticas en base a ello.

Para su recolección se definió un proceso, éste, descrito en la Figura A.1 corresponde a una iteración de n veces sobre el subproceso descrito en la Figura A.2, que es, en realidad, aquel que realiza la búsqueda de nuevos *tweets*.




Figura A.1: Proceso de iteración en RapidMiner.
Fuente: Elaboración Propia, (2016)

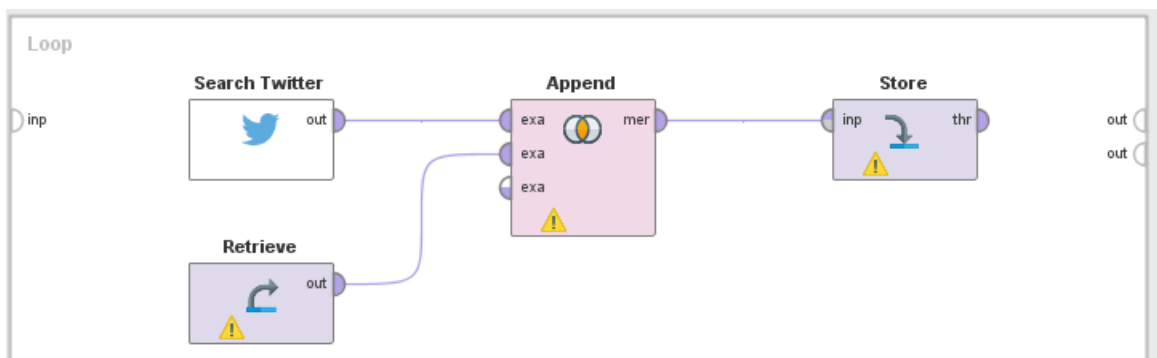


Figura A.2: Subproceso de recolección de estados en RapidMiner.
Fuente: Elaboración Propia, (2016)

Se recolectaron 67.789 *tweets* sólo con el idioma español en diferentes fechas, pues no se era capaz de obtener gran cantidad de datos debido a las limitaciones de *Twitter*. Sin importar el resto de los campos sólo se centra la atención en los correspondientes a la geolocalización presentados en la Figura A.3. La columna *Missing* indica que ese campo se encuentra vacío.

Name	Type	Missing	Statistics	Filter (2 / 12 attributes):
Geo-Location-Latitude	Numeric	67475	Min: -42.484	Max: 59.625 Average: -1.624
Geo-Location-Longitude	Numeric	67475	Min: -118.136	Max: 48.053 Average: -65.020

Figura A.3: Estadísticas de *tweets* con geolocalización.
Fuente: Elaboración Propia, (2016)

Éstos resultados señalan que sólo un 0.46% de los datos allí muestreados cuentan con el campo de geolocalización con datos, lo que lleva a hacer creer que el valor descrito en la literatura es cierto y justifica aún más la necesidad del operador presentado en la sección 4.4.2.

APÉNDICE B. CLAVES PARA EL USO DE LA *STREAM* API DE *TWITTER*

Para el uso de la API de *Twitter* se requiere de cuatro *tokens* de acceso. Éstos pueden ser obtenidos por cualquier persona que posea una cuenta en la red social. Para obtenerlos se debe acceder a la página: <https://apps.twitter.com/>. Allí en la parte superior derecha se encuentra la opción "*Create New App*" como se muestra en la Figura B.1.




Figura B.1: Obtención de claves paso uno.
Fuente: Elaboración Propia, (2016)

Una vez realizado lo anterior corresponde llenar los datos solicitados como se muestra en la Figura B.2, aceptar los términos de desarrollador expuestos al final de la página y presionar el botón "*Create your Twitter application*".

Create an application

Figura B.2: Obtención de claves paso dos.
Fuente: Elaboración Propia, (2016)

La Figura B.3 muestra el siguiente paso en la pestaña "*Keys And Access Tokens*" donde se obtendrán las primeras dos claves de acceso. La tercera y cuarta claves se obtienen presionando el botón "*Regenerate Consumer Key and Secret*", se solicitará confirmación y posterior a ello se redirige a la vista presentada en la Figura B.3. Para obtener las claves debe

presionarse, finalmente, el botón *"Test OAuth"*, se redirigirá a la página presentada en la Figura B.4 donde se muestran todas las claves.

Aplicacion de prueba USACH

Test OAuth

Details

Settings

Keys and Access Tokens

Permissions

Application Settings

Keep the "Consumer Secret" a secret. This key should never be human-readable in your application.

Consumer Key (API Key)	MJu1nAJYCiHP56CbIlFQcIdoG
Consumer Secret (API Secret)	rtrUomWLJy8fhR7rQCdqbjYmuvROTqRlqzgF4bLLlyjRLNgDiD
Access Level	Read and write (modify app permissions)
Owner	TebanAbarca
Owner ID	361365793

Application Actions

Regenerate Consumer Key and Secret

Change App Permissions

Figura B.3: Obtención de claves paso tres.
Fuente: Elaboración Propia, (2016)

OAuth Tool

OAuth Settings

Consumer key: *

UGLYZENNY79KHXzNA2FNzUGqt

Consumer secret: *

Jp2R2C65Wk90a6VGG3hPlpXrJCD5GmPfsz2CYzVJEf9iOjdDeE

Remember this should not be shared.

Access token:

Access token secret:

Figura B.4: Obtención de claves paso final.
Fuente: Elaboración Propia, (2016)